Super AI Engineer Season 6

Five Hackathons

April 3, 2026

Details

- Participate in 5 Hackathon competitions on Kaggle within 24 hours under the following challenge domains:
    1. Image Processing
    2. Natural Language Processing
    3. Signal Processing
    4. Data Science
- Each challenge has a separate competition leaderboard.

House Recognition

Image Processing

Example

No

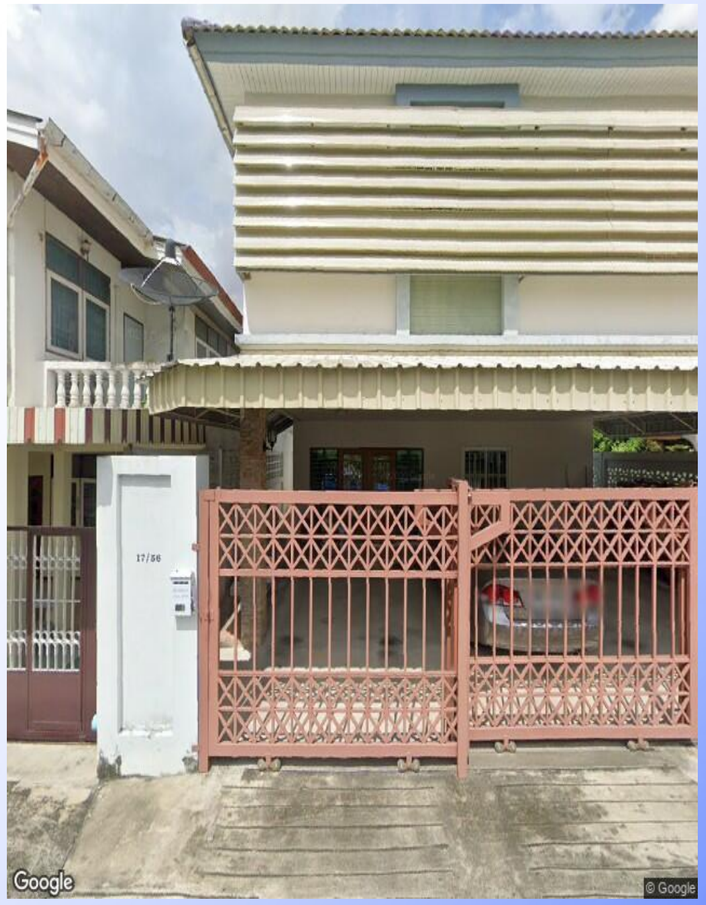

Yes

Dataset

Training Set: 2,954 Images

Test Set: 1,550 Images

Answer Format

0

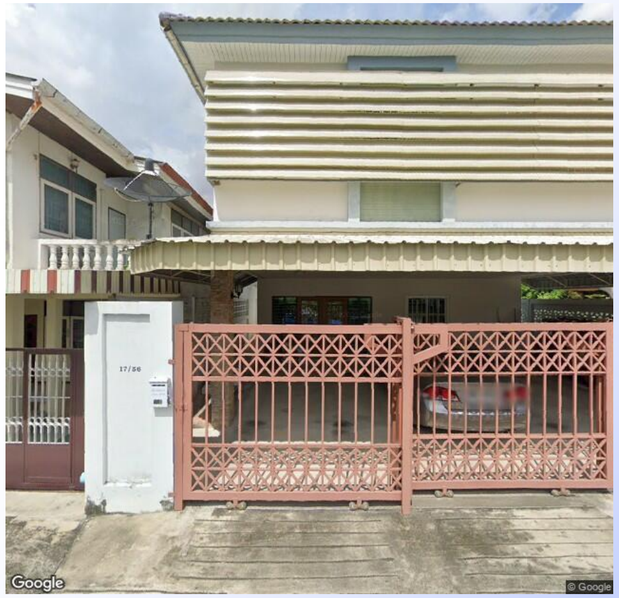

1

sample_submission.csv

id	answer
e4b420b0	0
23efa479	0
1f0f2402	0
...	...
af393f0c	

Evaluation

Evaluation Metric: Accuracy Score

Public Leaderboard: 50%

Private Leaderboard: 50%

Word Segmentation

Natural Language Processing

Dataset

Training Set: LST20 (Download from https://aiforthai.in.th/corpus.php **or** https://huggingface.co/datasets/lst-nectec/lst20)

On the Kaggle dataset, we have the **LST20 Annotation Guideline.pdf** and **LST20 Brief Specification.pdf** available as additional information.

Test Set: 37,248 characters (including whitespace)

Example of a test set

The 58th character

"ที่ยังสถานการณ์ยังไม่คลี่คลายอาจส่งผลกระทบการค้าชายแดนไทย - กัมพูชา ว่า เท่าที่เข้าไปดำเนินการตรวจสอบยังไม่พบว่ามีการปิดด่านบริเวณดังกล่าวและที่สำคัญการค้าระหว่างไทยและกัมพูชาส่วนใหญ่จะมีปริมาณมากที่ด่านปอยเปต อ. อรัญประเทศ จ. สระแก้ว..."

id	value
1	ท
2	ี
3	่
...	...
58	
...	...
37248	ว

whitespace

Answer Format

Additional information about the answer format:

- **ws_list.txt** - a list of possible predicted values
  - B_WORD: The first token of a word. This tag indicates that the token begins a new word
  - I_WORD: Tokens that appear in the middle of a word
  - E_WORD: The last token in a word. This tag indicates that the token completes a word
- **ws_sample_submission.csv** - a sample submission file in the correct format, contains 35,182 rows with the third solution answers (whitespace not included)

Id	Predicted
1	B_WORD
2	I_WORD
3	E_WORD
...	...
57	
59	
...	...
37248	

ws_sample_submission.csv

35,182 rows

Evaluation

Evaluation Metric: F1-score (Macro)

Public Leaderboard: 50%

Private Leaderboard: 50%

Sleep Stage Classification

Signal Processing

Example dataset

Features

labels

t

0

16Hz

t

n

BVP	ACC_X	ACC_Y	ACC_Z	TEMP	EDA	HR	IBI	Sleep_Stage
25.61	-22	-61	5	32.09	0.06532	72.85	1.0625	W
23.45	-22	-61	5	32.09	0.06532	72.85	1.0625	W
21.99	-22	-62	4	32.09	0.06532	72.85	1.0625	W
21.14	-22	-62	4	32.09	0.06532	72.85	1.0625	W
20.52	-19	-61	10	32.09	0.06532	72.85	1.0625	W
19.86	-19	-61	10	32.09	0.06532	72.85	1.0625	W
18.95	-19	-61	6	32.09	0.06532	72.85	1.0625	W
17.75	-19	-61	6	32.09	0.06532	72.85	1.0625	W
16.37	-23	-62	4	32.09	0.06532	72.85	1.0625	W
14.96	-23	-62	4	32.09	0.06532	72.85	1.0625	W
13.44	-24	-63	1	32.09	0.06532	72.85	1.0625	W
11.68	-24	-63	1	32.09	0.06532	72.85	1.0625	W
9.59	-21	-63	5	32.09	0.06532	72.85	1.0625	W
7.09	-21	-63	5	32.09	0.06532	72.85	1.0625	W
4.27	-19	-61	9	32.09	0.06532	72.85	1.0625	W
1.48	-19	-61	9	32.09	0.06532	72.85	1.0625	W

Features

BVP : Blood volume pulse derived from PPG sensor
IBI (ms) : Inter-beat interval (between individual heart beats)
EDA (µS) : Electrodermal activity from the galvanic skin response sensor
TEMP (°C) : Skin temperature from the infrared
ACC : Triaxial accelerometry with each axis
named ACC_X, ACC_Y, ACC_Z
HR (bpm) : Heart rate, estimated from the BVP
Sleep Stages : The technician-annotated sleep labels from PSG,
recorded every 30 seconds,
The possible values are N1, N2, N3, R, and W.

Dataset description

Sampling rate: 16Hz

- 1 second = 16 points

Segmentation : 30 seconds

- 1 label = 30 seconds

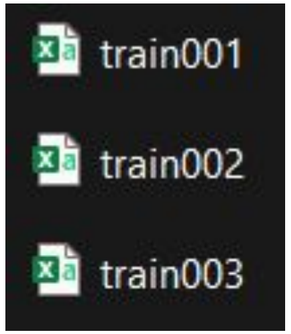

Train set : 83 subjects

Test set : 10 subjects

- **Segments : each 30 s**

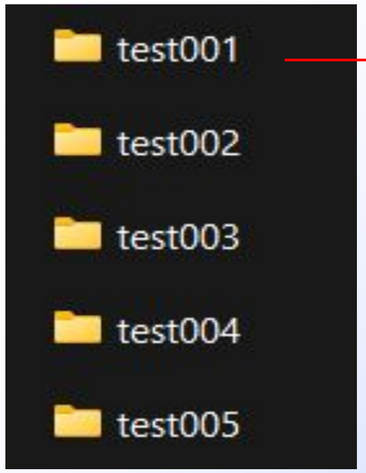

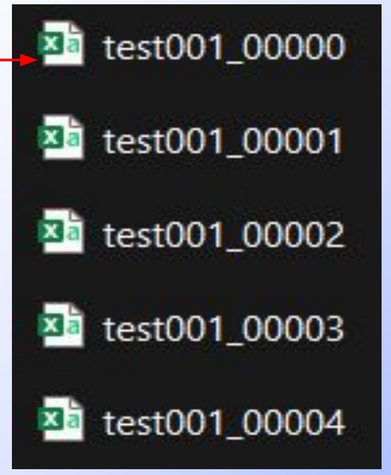

id	labels
test001_00000	W
test001_00001	W
test001_00002	W
test001_00003	W
test001_00004	W
test001_00005	W

Evaluation

Evaluation Metric: F1-Score (weighted)

Public Leaderboard: 50%

Private Leaderboard: 50%

Heart Disease Prediction

Data Science

Train dataset

Heart Disease Health Indicators

Train: 223,084 rows

Test: 74,361 rows

	ID	History of HeartDisease or Attack	High Blood Pressure	Told High Cholesterol	Cholesterol Checked	Body Mass Index	Smoked 100+ Cigarettes	Diagnosed Stroke	Diagnosed Diabetes	Leisure Physical Activity	...
0	train_000001	No	Yes	Yes	Yes	40.68	Yes	No	No	No	...
1	train_000002	No	No	No	No	24.36	Yes	No	No	Yes	...
2	train_000003	No	Yes	Yes	Yes	27.33	No	No	No	No	...

Feature columns

- **'History of HeartDisease or Attack': ‘ประวัติของโรคหัวใจหรือเคยมีอาการ’,**
- 'High Blood Pressure': 'ความดันโลหิตสูง',
- 'Told High Cholesterol': 'เคยได้รับการบอกว่ามีคอเลสเตอรอลสูง',
- 'Cholesterol Checked': 'เคยตรวจระดับคอเลสเตอรอล',
- 'Body Mass Index': 'ดัชนีมวลกาย (BMI)',
- 'Smoked 100+ Cigarettes': 'เคยสูบบุหรี่อย่างน้อย 100 มวนในชีวิต',
- 'Diagnosed Stroke': 'เคยได้รับการวินิจฉัยว่าเป็นโรคหลอดเลือดสมอง (Stroke)',
- 'Diagnosed Diabetes': 'เคยได้รับการวินิจฉัยว่าเป็นโรคเบาหวาน',
- 'Leisure Physical Activity': 'มีกิจกรรมเพื่อการพักผ่อนหรือออกกำลังกาย',
- 'Fruit or Vegetable Intake (1+ per Day)': 'บริโภคผลไม้หรือผัก อย่างน้อยวันละ 1 ครั้ง',
- 'Heavy Alcohol Consumption': 'บริโภคแอลกอฮอล์ในปริมาณมาก',
- 'Health Care Coverage': 'มีประกันสุขภาพหรือได้รับความคุ้มครองด้านสุขภาพ',
- 'Doctor Visit Cost Barrier': 'มีอุปสรรคด้านค่าใช้จ่ายในการพบแพทย์',
- 'General Health': 'สุขภาพโดยรวม (การประเมินตนเองเกี่ยวกับสุขภาพ)',
- 'Difficulty Walking': 'มีความยากลำบากในการเดินหรือเคลื่อนไหว',
- 'Sex': 'เพศ',
- 'Age': 'อายุ',
- 'Education Level': 'ระดับการศึกษา',
- 'Income Level': 'ระดับรายได้'

Train dataset

Some rows with missing values

	ID	History of HeartDisease or Attack	High Blood Pressure	Told High Cholesterol	Cholesterol Checked	Body Mass Index	Smoked 100+ Cigarettes	Diagnosed Stroke	Diagnosed Diabetes	Leisure Physical Activity
4	train_000005	NaN	Yes	Yes	Yes	34.56	Yes	No	No	Yes
10	train_000011	No	No	NaN	No	50.64	No	No	No	No
11	train_000012	No	Yes	NaN	No	13.64	Yes	No	No	Yes

Train dataset

Feature types

- Categorical feature
- Numerical feature
- Ordinal feature

General Health	Difficulty Walking	Sex	Education Level	Income Level	Age	Vegetable or Fruit Intake (1+ per Day)
Very Poor	Yes	Male	Some high school	$15,000 to less than $20,000	98	Yes
Poor	Yes	Male	High school graduate	($10,000 to less than $15,000	53	No
Poor	No	Male	Some high school	($10,000 to less than $15,000	65	Yes

Test dataset

	ID	High Blood Pressure	Told High Cholesterol	Cholesterol Checked	Body Mass Index	Smoked 100+ Cigarettes	Diagnosed Stroke	Diagnosed Diabetes	Leisure Physical Activity	Heavy Alcohol Consumption
0	test_000001	Yes	Yes	Yes	24.84	No	No	No	Yes	No
1	test_000002	Yes	No	Yes	29.08	Yes	No	No	No	No
2	test_000003	Yes	Yes	Yes	35.23	Yes	No	No	No	No
3	test_000004	No	No	Yes	24.78	Yes	No	No	No	No

Evaluation

Evaluation Metric: F2-score (average)

Public Leaderboard: 50%

Private Leaderboard: 50%

Thai Language Image Captioning

Image Processing + NLP

Dataset

MSCoco

Train: 114,287

Validation: 5,000

IPU 24

Train: 28,004

Validation: 4,036

Test: 2,000

MSCoco

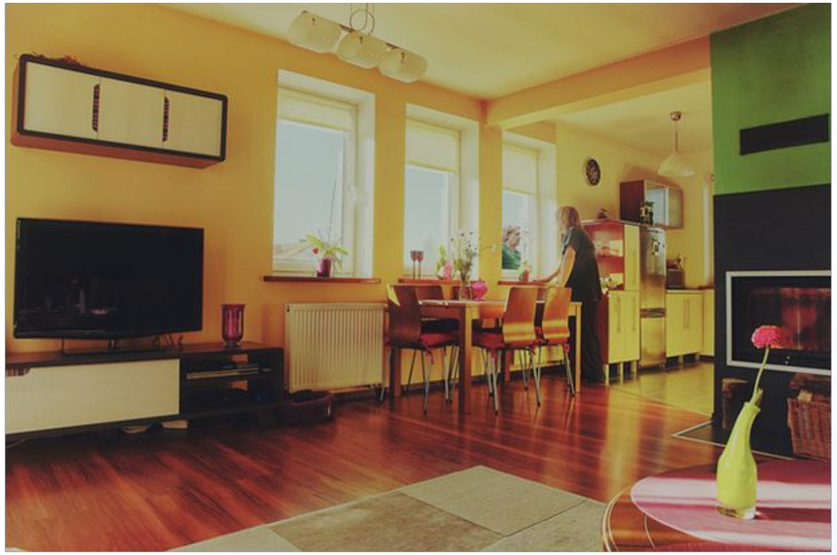

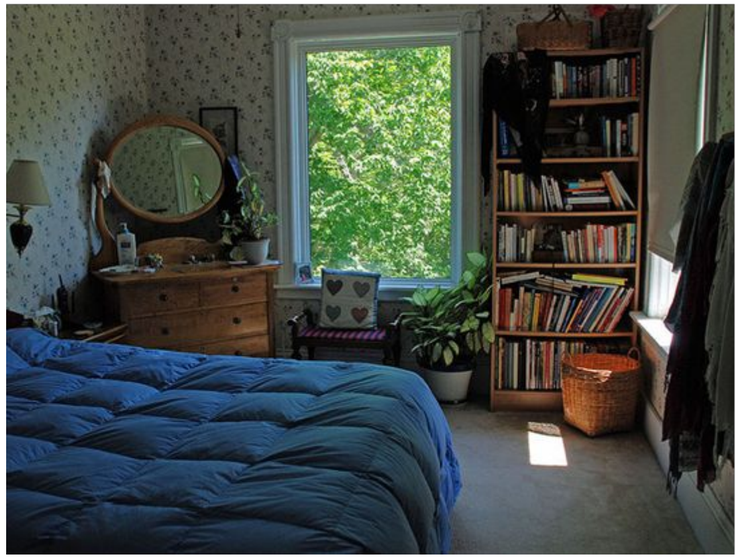

MSCoco

Can be downloaded from https://cocodataset.org/

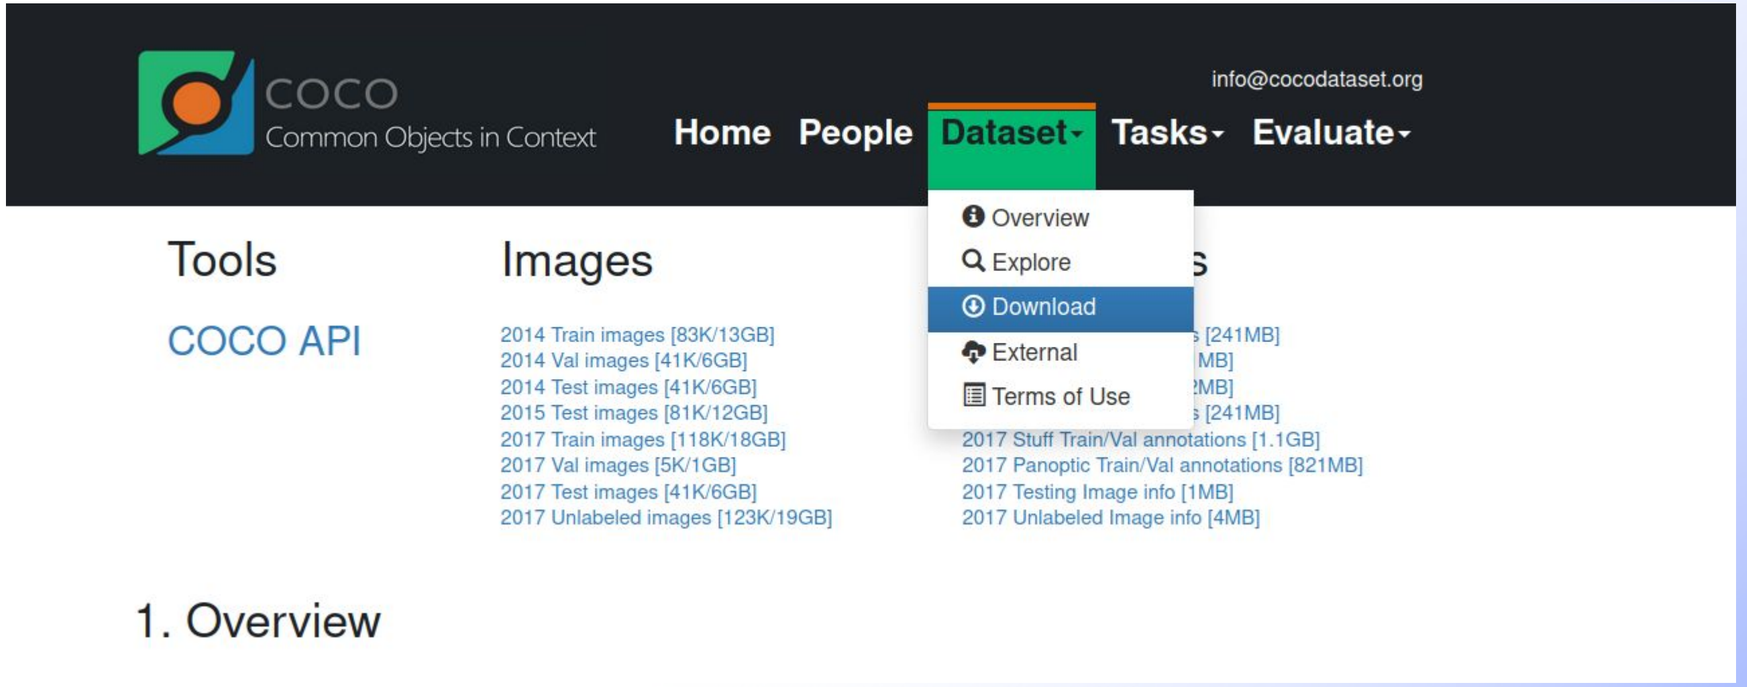

1. Overview

MSCoco

Can be downloaded from https://cocodataset.org/

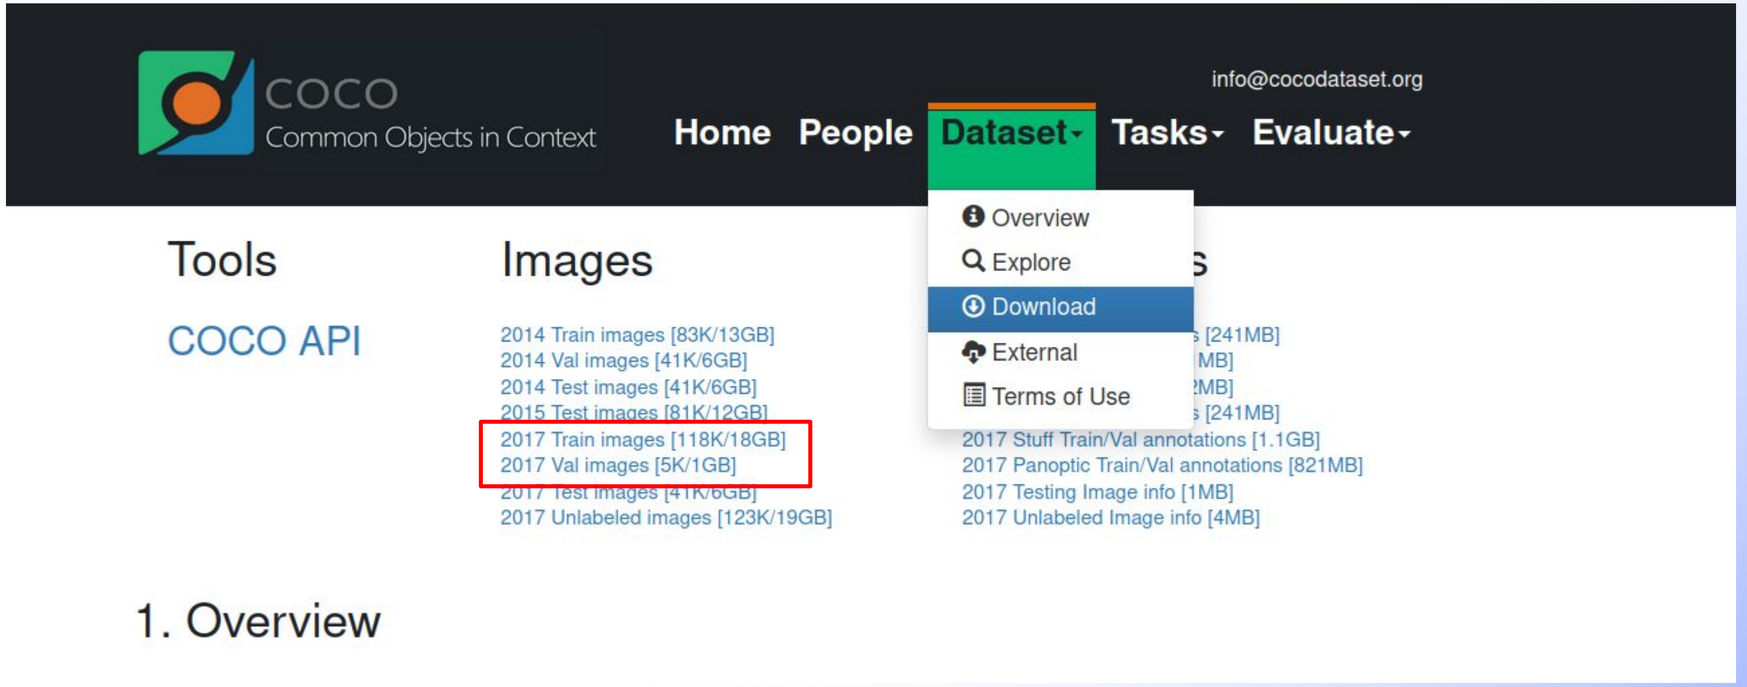

1. Overview

IPU 24

Annotations

```
"coco/val2017/000000060102.jpg" : [...] 3 items
"ipu24/val/travel/00000.jpg" : [...] 3 items
"coco/val2017/000000458702.jpg" : [...] 3 items
"ipu24/val/travel/00001.jpg" : [...] 3 items
"ipu24/val/food/00002.jpg" : [...] 3 items
"coco/val2017/000000441491.jpg" : [...] 3 items
"ipu24/val/travel/00003.jpg" : [...] 3 items
"ipu24/val/food/00004.jpg" : [...] 3 items
"coco/val2017/000000491613.jpg" : [...] 3 items
"ipu24/val/travel/00005.jpg" : [...] 3 items
"coco/val2017/000000557884.jpg" : [...] 3 items
"coco/val2017/000000152214.jpg" : [...] 3 items
"ipu24/val/food/00006.jpg" : [...] 3 items
"coco/val2017/000000418281.jpg" : [...] 3 items
"ipu24/val/travel/00007.jpg" : [...] 3 items
"ipu24/val/food/00008.jpg" : [...] 3 items
```

Image Directory

Evaluation

Evaluation Metric: BLEU score

- using Sacrebleu
- references_per_prediction = 3
- tokenized using sentencepiece flores101 tokenizer

Public Leaderboard: 50%

Private Leaderboard : 50%

Rules

- การแข่งขันเป็นรูปแบบรายบุคคล โดยผู้เข้าแข่งขันจะต้องตั้งชื่อทีมให้ถูกต้องตามที่กำหนด คือ "รหัสประจำตัวผู้อบรม-ชื่อจริงภาษาไทย" เช่น "600000-นงนุช" (ชื่อทีมสามารถเปลี่ยนได้หลังจาก Submission 1 ครั้ง)

  🚫 600000 - นงนุช

  🚫 600000_นงนุช

  ✅ 600000-นงนุช

- ห้ามใช้ Third-party API
- ห้ามใช้ Private Dataset
- ต้องมีการ Submit code ผ่าน mysuperai

Certificate

- สำหรับผู้ที่ผ่าน Baseline ทั้ง 5 โจทย์ เท่านั้น

Important Information

ระยะเวลาการแข่ง : Fri 3 Apr 19:00 - Sat 4 Apr 19:00

จำนวนครั้งในการส่ง : 5 ครั้ง/วัน, ตัดรอบ 07.00 น.

Kaggle link

House Recognition : https://www.kaggle.com/t/9cad135abb60463d87182c847e2f4e4f

Word Segmentation : https://www.kaggle.com/t/2d65cc35f74046869126c6a2ff4a3eeb

Sleep Staging Classification : https://www.kaggle.com/t/bf57743df0964d0f8130b6d063842b4c

Heart Disease Prediction : https://www.kaggle.com/t/ee48cbcbd794412f83aa20623a1cee76

Thai Language Image Captioning :
https://www.kaggle.com/t/6beab1a5681541f3ac5c3e519554e963

Q & A