

สรุปการประชุม

Technical Distillation Plan: Thai/English Small LLM ≤3B

เป้าหมายของงาน

ทีมต้องการทำโมเดลภาษาไทย/อังกฤษขนาดเล็กแบบ **Distilled Student Model** โดยมีเงื่อนไขหลักคือ

- ขนาดโมเดล Student ต้องไม่เกิน **3B parameters**
- เวลา train/fine-tune ไม่ควรเกิน **6-8 ชั่วโมง**
- ต้องเลือก data ที่ทำให้ loss ต่ำที่สุดและมีคุณภาพเหมาะกับ task ของทีม
- ต้องใช้แนวคิด **Teacher-Student Distillation**
- ต้องมี pipeline, architecture, paper/reference และโมเดล candidate ไม่เกิน 3 ตัว
- เน้นทำให้ทัน ใช้งานจริง และไม่ซับซ้อนเกินไป

2. ข้อสรุปเร็วที่สุด

Recommendation หลัก

ควรเลือกแนวทางนี้ก่อน:

Teacher: Qwen3-4B / Qwen3-8B / Typhoon2

Student: Qwen3-1.7B หรือ Llama 3.2-1B/3B

Technique:

Train Budget: 3–6 ชั่วโมง

Data: Thai-heavy instruction data + teacher-generated answers + loss/perplexity filtering

เหตุผลคือทำงานง่าย รวดเร็ว คุมเวลาได้ และไม่ต้องทำ logits distillation ที่ยุ่งยากมาก

Optimization

Model Research & Distillation Update

1. Objective / เป้าหมายหลักของการเลือก Pipeline

เป้าหมายของทีมคือการเลือกแนวทางพัฒนาโมเดลภาษาไทยขนาดเล็กที่สามารถตอบคำถามเชิงเหตุผลได้ดี โดยเฉพาะบริบทการศึกษาในประเทศไทย เช่น คำถามแนวข้อสอบเก่า คณิตศาสตร์ระดับมัธยมต้น และโจทย์ที่ต้องใช้ตรรกะในการคิดวิเคราะห์

จากภาพรวมเบื้องต้น ทีมกำลังพิจารณา pipeline หลัก 4 ทางเลือก ได้แก่

1. **Train model with Thai only**
ฝึกโมเดลด้วยข้อมูลภาษาไทยเป็นหลัก
2. **Train Thai from scratch → Distillation**
ฝึกโมเดลภาษาไทยตั้งแต่ต้น แล้วค่อยทำ distillation
3. **Distillation → Train Thai**
เริ่มจากการ distill ความรู้จากโมเดลใหญ่ แล้วค่อยนำไปฝึกต่อด้วยข้อมูลภาษาไทย
4. **Distillation with Large Thai LLM**
ใช้ Large Thai LLM เป็น Teacher Model เพื่อถ่ายทอดความรู้ให้ Student Model

2. Current Teacher / Student Model Candidates

Teacher Model

โมเดลที่ถูกเสนอให้ใช้เป็น Teacher Model ได้แก่

1. **Siam GPT 32B**
เหมาะสำหรับใช้เป็นโมเดลครูในบริบทภาษาไทย เพราะมีขนาดใหญ่และน่าจะมีความสามารถด้านภาษาไทยที่ดีกว่าโมเดลเล็ก
2. **Qwen 32B**
เป็นโมเดลขนาดใหญ่ที่มีความสามารถด้าน reasoning และ general knowledge ค่อนข้างแข็งแกร่ง เหมาะสำหรับใช้สร้าง reasoning data หรือใช้เป็น teacher สำหรับ distillation

Student Model

โมเดลนักเรียนที่ถูกเสนอในภาพรวมคือ

Qwen 0.8B

เหตุผลคือขนาดเล็ก เหมาะกับการ train / fine-tune / distill ภายในเวลาจำกัด และเหมาะกับเป้าหมายการสร้างโมเดลไม่เกินระดับประมาณ 1B–3B parameters

3. Research Update จากทีม Research

3.1 WangchanLion

ทีม Research มีการหาข้อมูลเกี่ยวกับโมเดลหรือชุดงานที่เกี่ยวข้อง เช่น **WangchanLion 3** เพื่อดูว่าแนวทางเหล่านี้สามารถนำมาใช้กับงานภาษาไทยได้มากน้อยแค่ไหน

ประเด็นที่ต้องดูต่อคือ

- โมเดลหรือ dataset เหล่านี้รองรับภาษาไทยได้ดีแค่ไหน
- มีข้อมูลแนว reasoning หรือไม่
- เหมาะกับการนำมาใช้เป็น baseline, teacher, หรือ data source หรือไม่
- สามารถนำไป fine-tune / distill ต่อได้ง่ายหรือไม่

3.2 Mangosteen Corpus

ทีมได้พูดถึง **Mangosteen Corpus** ซึ่งเป็นแหล่งข้อมูลภาษาไทยที่น่าสนใจ โดยเฉพาะในลักษณะ question-answer ภาษาไทย

จุดเด่นที่คาดว่าจะใช้ได้:

- มีข้อมูลภาษาไทย
- มีลักษณะเป็นคำถาม-คำตอบ
- อาจเหมาะสำหรับใช้เป็น instruction / QA data เบื้องต้น

ข้อจำกัดที่พบ:

- ยังขาดข้อมูลแบบ **specific reasoning**
- ยังไม่แข็งแรงพอสำหรับโจทย์ที่ต้องใช้ตรรกะหลายชั้น
- อาจตอบคำถามภาษาไทยทั่วไปได้ แต่ยังไม่เหมาะกับโจทย์คณิตศาสตร์หรือโจทย์แนววิเคราะห์เชิงลึก

ดังนั้น Mangosteen Corpus อาจเหมาะเป็นข้อมูลพื้นฐานด้านภาษาไทย แต่ไม่ควรใช้เป็น data หลักเพียงอย่างเดียวสำหรับเป้าหมาย reasoning

4. Motivation for Version 4

ทีมต้องการสร้าง **Version 4** ของโมเดล โดยเน้นความสามารถด้านการตอบคำถามเพื่อการศึกษาในประเทศไทย

เป้าหมายของ Version 4 คือ

- ตอบคำถามภาษาไทยได้ดีขึ้น
- เข้าใจโจทย์เชิงตรรกะมากขึ้น
- รองรับโจทย์แนวข้อสอบเก่า
- เน้นการอธิบายเหตุผล ไม่ใช่แค่ตอบคำตอบสุดท้าย
- ช่วยสนับสนุนการเรียนรู้ของนักเรียนไทย

จุดสำคัญคือโมเดลไม่ควรเป็นแค่ chatbot ภาษาไทยทั่วไป แต่ควรเป็น **Educational Reasoning Model** ที่ตอบแบบมีตรรกะและช่วยอธิบายขั้นตอนการคิดได้

5. Data Direction / แนวทางข้อมูลที่ต้อง Research ต่อ

ทีมต้องหา data sources เพิ่มเติม โดยเฉพาะข้อมูลที่เกี่ยวข้องกับการศึกษาและ reasoning ภาษาไทย

5.1 ประเภทข้อมูลที่ต้องการ

ข้อมูลที่ควรเน้น ได้แก่

1. ข้อสอบเก่า

เช่น

- ข้อสอบวิทยาศาสตร์
- ข้อสอบ logic / reasoning
- ข้อสอบเข้า ม.1 / ม.4
- ข้อสอบ O-NET หรือแนวข้อสอบมาตรฐานอื่น ๆ

2. ข้อมูล Question-Answer ภาษาไทย

ใช้สำหรับสอนให้โมเดลเข้าใจรูปแบบคำถามและการตอบเป็นภาษาไทย

3. ข้อมูล Chain-of-Thought / Reasoning

ต้องการข้อมูลที่มีลักษณะ:

- วิเคราะห์โจทย์
- แยกเงื่อนไข
- อธิบายขั้นตอน
- ค่อย ๆ หาคำตอบ
- ตรวจสอบคำตอบ

4. ข้อมูล Math Word Problem ภาษาไทย

ควรรหาโจทย์ที่เป็นภาษาไทยและมีคำอธิบายวิธีทำ เช่น

- สมการพหุนาม
- อัตราส่วน
- เปอร์เซนต์
- เรขาคณิตเบื้องต้น
- ลำดับและอนุกรมเบื้องต้น
- ปัญหาเชิงตรรกะ

5. ข้อมูล General Knowledge + Business + Finance

ทีม F1 มีการพูดถึงการใช้ข้อมูลที่หาเอง เช่น

- general knowledge
- business
- finance

ข้อมูลกลุ่มนี้ช่วยเพิ่มความสามารถรอบด้านของโมเดล แต่ไม่ควรกลบเป้าหมายหลักด้าน education reasoning

6. Model Experiments จากทีม F1

ทีม F1 มีการทดลองและเสนอแนวทางหลายแบบ โดยสามารถสรุปเป็นกลุ่มหลักได้ดังนี้

6.1 ทดลองโมเดลขนาดเล็ก

ทีม F1 ทดลองหรือพิจารณาโมเดลกลุ่มเล็ก เช่น

- Qwen 3.5 0.8B
- Gemma 4 1B
- Qwen 3 0.6B
- Qwen 2.5
- Typhoon Model S

เป้าหมายคือหา student model ที่เล็กพอสำหรับ train ได้เร็ว แต่ยังมี performance ดีพอสำหรับภาษาไทยและ reasoning

6.2 Optimization บน Qwen

ทีมมีการทดลอง optimize โมเดลสาย Qwen ได้แก่

- Qwen 3 0.6B
- Qwen 2.5
- Qwen 3.5 0.8B
- Qwen 3.5 4B

แนวทางนี้น่าสนใจ เพราะ Qwen โดยทั่วไปมีความสามารถด้าน reasoning ค่อนข้างดี และมีโมเดลหลายขนาดให้เลือก ทำให้สามารถทดลองเปรียบเทียบได้ง่าย

6.3 Typhoon Model S + On-policy Distillation

มีการพูดถึงการใช้ **Typhoon Model S** ร่วมกับ **on-policy distillation**

แนวคิดคือให้โมเดล student สร้างคำตอบของตัวเอง แล้วใช้ teacher หรือ reward/checking mechanism ช่วยปรับปรุงคำตอบนั้นต่อ

ข้อดีของแนวทางนี้:

- ช่วยให้ student model เรียนรู้จากพฤติกรรมของตัวเอง
- เหมาะกับ reasoning task
- อาจทำให้โมเดลตอบได้เป็นธรรมชาติกว่า supervised fine-tuning อย่างเดียว

ข้อควรระวัง:

- ต้องมี teacher ที่ให้ feedback ได้ดี
- ต้องควบคุมคุณภาพคำตอบ
- ถ้า data หรือ reward ไม่ดี อาจทำให้โมเดลเรียนรู้ผิดทาง

7. Proposed Experiment Directions / แนวทางทดลอง 3 แบบ

จาก notes ของทีม F1 สามารถสรุปเป็นแนวทางทดลองหลักได้ประมาณ 3 แบบ

Experiment 1: ใช้ Qwen 3.5 4B แล้วลดขนาดเหลือประมาณ 1B

แนวทาง:

ใช้ Qwen 3.5 4B เป็น base แล้วตัด layer หรือปรับ architecture ให้เหลือขนาดประมาณ 1B

แนวคิดนี้คือการทำ **model compression / layer pruning** เพื่อลดขนาดโมเดล

ข้อดี:

- ได้ student ที่สืบทอดโครงสร้างจากโมเดลใหญ่
- อาจรักษาความสามารถ reasoning ได้มากกว่า train เล็กจากศูนย์
- เหมาะกับเป้าหมายสร้างโมเดลเล็กแต่ยังฉลาด

ข้อเสีย:

- การตัด layer อาจทำให้ performance drop
- ต้องมีขั้นตอน recovery training หลังตัด layer
- ต้องออกแบบว่า layer ไหนควรถูกตัด
- ต้อง benchmark อย่างละเอียดก่อนตัดสินใจว่าเวิร์คจริง

Experiment 2: Qwen 3.5 4B → Knowledge Distillation

แนวทาง:

ใช้ Qwen 3.5 4B หรือโมเดลใหญ่กว่าเป็น teacher แล้ว distill ไปยัง student model ขนาดเล็ก เช่น 0.6B / 0.8B / 1B

นี่เป็นแนวทางที่เหมาะสมมากสำหรับโจทย์นี้ เพราะเป้าหมายคือได้โมเดลเล็กที่ reasoning ดีขึ้นภายใต้เวลาจำกัด

ข้อดี:

- ไม่ต้อง train from scratch
- ใช้ teacher ช่วยสร้างคำตอบคุณภาพสูง
- เหมาะกับ educational QA และ reasoning
- สามารถใช้ data ที่ทีมสร้างเองร่วมกับ teacher-generated data ได้

ข้อเสีย:

- คุณภาพ student ขึ้นกับคุณภาพ teacher
- ต้องกรองคำตอบ teacher ที่ผิด
- ต้องออกแบบ prompt สำหรับ teacher ให้ดี
- ต้องเลือก distillation format ให้เหมาะสม เช่น answer-only, explanation, step-by-step, hint-based

Experiment 3: ใช้ Data ของทีม F1 + General / Business / Finance Data

แนวทาง:

นำข้อมูลที่ทีม F1 หาเอง เช่น general, business, finance มาฝึกหรือ fine-tune ร่วมกับข้อมูล education reasoning

ข้อดี:

- เพิ่มความสามารถรอบด้าน
- ทำให้โมเดลตอบคำถามทั่วไปได้ดีขึ้น
- ช่วยให้โมเดลไม่แคบเกินไป

ข้อควรระวัง:

- ถ้าใช้ข้อมูล general มากเกินไป อาจทำให้โมเดลไม่เด่นด้าน education
- ควรจัด data ratio ให้ดี
- ควรแยกชุดข้อมูล reasoning, Thai QA, general knowledge, business/finance ให้ชัดเจน

8. Pipeline Recommendation

จากข้อมูลตอนนี้ แนวทางที่เหมาะสมที่สุดควรเป็น

Recommended Pipeline

Thai Educational Data + Reasoning Data → Teacher Generation → Filtering → Distillation → Thai Fine-tuning → Evaluation

หรือเขียนเป็น pipeline ได้แบบนี้

1. Collect Thai education data

↓

2. Prepare reasoning-style QA dataset

↓

3. Use large teacher model to generate explanations

↓

4. Filter low-quality answers

↓

5. Distill into small student model

↓

6. Fine-tune on Thai-specific data

↓

7. Evaluate with Thai exam / reasoning benchmark

9. Recommended Model Strategy

Teacher Model

ควรใช้ teacher อย่างน้อย 1–2 ตัวเพื่อเปรียบเทียบ เช่น

1. Qwen 32B

ใช้สำหรับ reasoning, math, logic และการสร้างคำตอบแบบมีขั้นตอน

2. Siam GPT 32B หรือ Large Thai LLM

ใช้สำหรับปรับภาษาไทยให้เป็นธรรมชาติ และตรวจสอบความเหมาะสมกับบริบทไทย

แนวทางที่ดีที่สุดอาจเป็นการใช้ teacher แบบผสม:

Qwen 32B = reasoning teacher

Large Thai LLM = Thai language / localization teacher

Student Model

ตัวเลือก student ที่ควรทดลองก่อน:

1. Qwen 0.8B / Qwen 3.5 0.8B

เหมาะเป็นตัวหลัก เพราะเล็กและมีพื้นฐาน reasoning ดี

2. Qwen 3.5 0.6B

เหมาะเป็นตัวทดลองที่เล็กกว่า เพื่อดูว่า performance ยังพอรับได้หรือไม่

3. Gemma 4 1B

ใช้เป็น comparison baseline

10. Data Strategy

ควรแบ่ง dataset เป็น 4 กลุ่มหลัก

10.1 Thai QA Data

ใช้สำหรับให้โมเดลตอบภาษาไทยได้ดี

ตัวอย่าง:

- Mangosteen Corpus
- Thai QA datasets
- ข้อมูลคำถาม-คำตอบทั่วไปภาษาไทย

10.2 Thai Educational Data

ใช้สำหรับเป้าหมายหลักด้านการศึกษา

ตัวอย่าง:

- ข้อสอบเก่า
- โจทย์คณิตศาสตร์ ม.ต้น
- โจทย์วิทยาศาสตร์
- โจทย์ตรรกะ
- แบบฝึกหัดพร้อมเฉลย

10.3 Teacher-generated Reasoning Data

ให้ teacher model สร้างคำตอบแบบอธิบายเหตุผลจากโจทย์

ควรมี format เช่น

```
{  
  "question": "โจทย์ภาษาไทย",  
  "reasoning": "อธิบายวิธีคิดทีละขั้น",  
  "answer": "คำตอบสุดท้าย"  
}
```

หรือแบบปลอดภัยกว่าสำหรับ production:

```
{  
  "question": "โจทย์ภาษาไทย",  
  "explanation": "คำอธิบายแบบกระชับ",  
}
```

```
"answer": "คำตอบสุดท้าย"  
}
```

10.4 General Knowledge Data

ใช้เสริมความรู้ทั่วไป เช่น

- business
- finance
- general knowledge
- everyday Thai conversation

แต่ควรให้เป็นสัดส่วนรองจาก education reasoning data

11. Training Strategy

Stage 1: Baseline Fine-tuning

เริ่มจาก fine-tune student model ด้วย Thai QA และ educational QA ก่อนเพื่อดู baseline

Stage 2: Supervised Distillation

ใช้คำตอบจาก teacher model มาสอน student โดยตรง

รูปแบบข้อมูล:

Question → Teacher Explanation → Final Answer

Stage 3: Reasoning-focused Fine-tuning

เพิ่มข้อมูลโจทย์ตรรกะและคณิตศาสตร์ที่มี explanation คุณภาพสูง

Stage 4: Thai Localization

ปรับให้โมเดลตอบเป็นภาษาไทยที่อ่านง่าย เหมาะกับนักเรียนไทย

Stage 5: Evaluation

วัดผลกับชุดทดสอบที่แยกออกมา เช่น

- ข้อสอบคณิต ม.ต้น
- คำถาม reasoning
- คำถามภาษาไทยทั่วไป
- คำถามที่ต้องอธิบายขั้นตอน
- คำถามหลอกหรือโจทย์ที่มีเงื่อนไขซับซ้อน

12. Evaluation Metrics

ควรประเมินทั้งเชิงตัวเลขและเชิงคุณภาพ

12.1 Automatic Evaluation

เช่น

- accuracy
- exact match
- multiple-choice accuracy
- loss
- perplexity
- reasoning answer correctness

12.2 Human Evaluation

ให้คนตรวจว่าโมเดลตอบดีหรือไม่ โดยดูจาก

- คำตอบถูกหรือไม่
- อธิบายเข้าใจง่ายหรือไม่
- ภาษาไทยเป็นธรรมชาติหรือไม่
- เหมาะกับนักเรียนไทยหรือไม่
- มี hallucination หรือไม่
- วิธีคิดสมเหตุสมผลหรือไม่

13. Main Risks

13.1 Data ขาด Reasoning

ตอนนี้ data ภาษาไทยหลายตัวมี QA แต่ยังไม่ใช้ reasoning data ที่ดีพอ

แนวทางแก้:

- ใช้ teacher model สร้าง explanation
- ใช้ข้อสอบเก่า + เฉลย
- สร้าง template reasoning สำหรับคณิตและตรรกะ
- กรองคำตอบที่ผิดออก

13.2 Student Model เล็กเกินไป

โมเดล 0.6B–0.8B อาจไม่เก่ง reasoning เท่า 3B–7B

แนวทางแก้:

- ใช้ teacher คุณภาพสูง
- ใช้ distillation แบบเน้น reasoning
- เพิ่ม training data เฉพาะทาง
- เปรียบเทียบ 0.6B, 0.8B, 1B และ 3B ถ้ามีเวลา

13.3 Train From Scratch อาจไม่คุ้ม

การ train from scratch ต้องใช้ data และ compute เยอะมาก

แนวทางที่ควรให้ priority มากกว่า:

Pretrained small model → Thai SFT → Reasoning distillation

มากกว่า

Train from scratch

14. Recommended Final Direction

แนวทางที่แนะนำสำหรับทีมตอนนี้คือ

Best Practical Direction

ใช้ **Qwen 0.8B / Qwen 3.5 0.8B** เป็น student model แล้วใช้ **Qwen 32B + Large Thai LLM** เป็น teacher เพื่อทำ reasoning distillation จากข้อมูลข้อสอบเก่าและโจทย์ภาษาไทย

Pipeline ที่เหมาะสมที่สุดคือ

Collect Thai exam/reasoning data

→ Generate reasoning answers with Qwen 32B

→ Improve Thai explanation with Large Thai LLM

→ Filter bad samples

→ Distill into Qwen 0.8B student

→ Fine-tune with Thai education data

→ Evaluate on Thai exam benchmark

เหตุผลที่เลือกแนวทางนี้:

- เร็วกว่าการ train from scratch
- เหมาะกับเวลาจำกัด
- ใช้ประโยชน์จาก teacher model ขนาดใหญ่ได้เต็มที่
- ทำให้ student model เล็กแต่ reasoning ดีขึ้น
- ตรงกับเป้าหมายด้าน education ในประเทศไทย
- สามารถทดลองหลาย student model ได้ภายในเวลาไม่มาก

15. สรุปสั้นสำหรับใส่ Executive Summary

ทีมกำลังหาแนวทางสร้างโมเดลภาษาไทยขนาดเล็กที่ตอบคำถามเชิงเหตุผลได้ดี โดยเน้น use case ด้านการศึกษาในประเทศไทย เช่น ข้อสอบเก่า คณิตศาสตร์ ระดับมัธยมต้น และโจทย์ตรรกะ ปัจจุบันทีมพิจารณา 4 pipeline หลัก ได้แก่ train Thai only, train from scratch แล้ว distill, distill ก่อนแล้ว train ภาษาไทย และ distillation ด้วย Large Thai LLM

จากการ research เบื้องต้น พบว่า dataset ภาษาไทยที่มีอยู่ เช่น Mangosteen Corpus เหมาะกับ question-answer ทั่วไป แต่ยังขาด reasoning data ที่เฉพาะ

เจาะจง ทีมจึงต้องหาแหล่งข้อมูลเพิ่มเติม เช่น ข้อสอบเก่า โจทย์คณิต และข้อมูล reasoning ภาษาไทย

ฝั่ง F1 มีการทดลองหลายแนวทาง เช่น Qwen 3.5 0.8B, Gemma 4 1B, Qwen 3 0.6B, Qwen 2.5, Typhoon Model S และการใช้ Qwen 3.5 4B เพื่อทำ layer reduction หรือ knowledge distillation โดยแนวทางที่เหมาะสมที่สุดในระยะสั้น คือใช้ Qwen 0.8B เป็น student model และใช้ Qwen 32B ร่วมกับ Large Thai LLM เป็น teacher เพื่อสร้าง reasoning data และ distill ความรู้ลงมายังโมเดลขนาดเล็ก

สรุปคือทีมควรโฟกัสที่ pipeline:

Thai Educational Data

→ Teacher Reasoning Generation

→ Data Filtering

→ Knowledge Distillation

→ Thai Fine-tuning

→ Evaluation

Distillation

Paper: Pre-training Distillation for Large Language Models: A Design Space Exploration (<https://arxiv.org/pdf/2410.16215>) (paper นี้ไม่มี code)


Summary: Student เรียนจาก "Input Data" เพื่อรู้พื้นฐานภาษา และเรียนจาก "Teacher's Logits" เพื่อลอกเลียนแบบ "ตรรกะหรือความเข้าใจ" ของ Teacher

Paper: LLM-NEO: Parameter Efficient Knowledge Distillation for Large Language Models (<https://arxiv.org/abs/2411.06839>)

Summary: LLM-Neo คือ framework ที่เอา LoRA มาใช้ร่วมกับ Knowledge Distillation เพื่อถ่ายโอนความรู้จาก LLM ใหญ่ไปยัง LLM เล็กอย่างมีประสิทธิภาพ โดยที่เลือกใช้ LoRA ร่วมด้วยเพื่อประหยัด memory, compute และเพิ่มประสิทธิภาพการเรียนรู้

coding tutorial from pytorch

- [Knowledge Distillation Tutorial — PyTorch Tutorials 2.12.0+cu130 documentation](#)
- [Distilling Llama3.1 8B into Llama3.2 1B using Knowledge Distillation — torchtune 0.3 documentation](#)



Full Picture Pipeline: Adapt-and-Distill (SiamGPT 32B > Qwen 3.5 0.8B)

Phase 1: Domain Adaptation (การเตรียมพื้นฐานความรู้ไทย)

1. **Vocabulary Alignment:** เนื่องจาก SiamGPT (151k) และ Qwen 3.5 (248k) มีคลังคำศัพท์ไม่เท่ากัน ต้องใช้อัลกอริทึม **Dual Space Knowledge Distillation** (DSKD) เพื่อโปรเจกต์ Embedding ของทั้งคู่เข้าสู่พื้นที่เดียวกันก่อนเริ่มการถ่ายทอดความรู้
 2. **Warm-up SFT (Student):** นำโมเดลนักเรียน (0.8B) มาทำ Supervised Fine-tuning (SFT) บนชุดข้อมูลภาษาไทยเฉพาะทางของคุณ ก่อน 1 รอบ
- Precision: ใช้ BF16 mixed precision เพื่อความเสถียรเชิงตัวเลข
Goal: เพื่อให้พารามิเตอร์ของนักเรียนเริ่ม "จดจำ" รูปแบบภาษาไทยก่อนรับการถ่ายทอดตรรกะขั้นสูงจากครู

Phase 2: Knowledge Distillation with Integrated Quantization (การเรียนรู้พร้อมบีบอัด)

3. **Strong-to-Weak Logits Distillation:** ให้นักเรียนเรียนรู้จากค่าความน่าจะเป็น (Logits) ของ SiamGPT 32B
 - On-policy Distillation:** ให้นักเรียนลองตอบคำถามจากข้อมูลไทย แล้วนำคำตอบมาเทียบกับครูเพื่อปรับจุดตรรกะการคิด (KL Divergence)
 4. **Native FP8 Training (Quantize ระหว่างเทรน):** ใช้โครงสร้างพื้นฐานของ Qwen 3.5 เพื่อทำ Low-precision training ไปพร้อมกัน
- FP8 Pipeline:** ใช้ความละเอียด FP8 กับส่วนของ Activations และ GEMM operations ตลอดการเทรนเพื่อลดการใช้หน่วยความจำลง 50%
Runtime Monitoring: ระบบจะเฝ้าระวังและรักษาค่าเป็น BF16 ในเลเยอร์ที่อ่อนไหว (Sensitive layers) เพื่อป้องกันข้อมูลสูญหาย

Phase 3: Architecture Optimization (การปรับแต่งโครงสร้าง GDN)

5. **MatMul-only Matrix Inversion:** สำหรับสถาปัตยกรรม Gated DeltaNet (GDN) ของนักเรียน ให้เปลี่ยนการคำนวณ Matrix Inversion เป็นแบบ Neumann expansion
- Diagonal Masking: ใช้การ Mask ค่าที่เกินขอบเขตเพื่อกำจัด Quantization noise
Residual Correction: ทำการแก้ค่าคลาดเคลื่อน (Residual steps = 8) เพื่อให้โมเดล 0.8B ยังคงความแม่นยำเทียบเท่า FP16 แม้จะถูกบีบอัด

Phase 4: Final Deployment (การเตรียมนำไปใช้)

6. Post-Training Quantization (PTQ): หลังเทรนเสร็จ ให้แปลงส่วนที่เหลือเป็น INT8 หรือ INT16 สำหรับส่วน Kernel

70% Thai / 30% Eng

Based-on papers, This is recommended training setup from the paper

For qwen 0.8B

Token amount

Small proof-of-concept: 1B–10B tokens

Serious experiment: 50B–100B tokens

Close to paper baseline: 100B tokens

Stronger training: 500B tokens

Epochs

The paper does not specify training by epochs. It trains by token budget. $\text{epochs} =$

$\frac{\text{target_training_tokens}}{\text{total_tokens_indataset}}$

qwen 0.8B target_training_tokens = 30-50B tokens (Serious experiment)

Optional Training Technique: Offline KD แบบแยก compute pool (แยกเทรน logits ล่วงหน้า)