


Time Series Analysis

From Demand Forecasting to Causality and Beyond

เอกสารสรุปภาษาไทยแบบละเอียด พร้อมตาราง ตัวอย่าง และภาพประกอบจากสไลด์



ภาพจากสไลด์หน้า 58: The Time Series Ecosystem - Prediction, Causality, Structure, Coordination

เป้าหมายของเอกสาร: อ่านแล้วเข้าใจว่า Time Series ไม่ใช่แค่การพยากรณ์ แต่รวมถึงการหาเหตุผลเชิงเวลา การแยกองค์ประกอบของสัญญาณ และการวิเคราะห์ความเป็นผู้นำ/ผู้ตามในระบบหลายตัวแปร


แหล่งเนื้อหา: สไลด์ Time Series Analysis: From Demand Forecasting to Causality and Beyond โดย Chainarong Amornbunchornvej, Ph.D. เรียบเรียงใหม่เป็นภาษาไทยเพื่อการอ่านและทบทวน

สารบัญแบบอ่านเร็ว

ลำดับ	หัวข้อ	ควรจำให้ได้
1	ภาพรวม Time Series Analysis	What / Why / How / Use in project
2	Four Questions of Signal Analysis	What / Why / How / Use in project
3	Anatomy of a Signal: Trend, Seasonality, Noise	What / Why / How / Use in project
4	Demand Forecasting	What / Why / How / Use in project
5	Multi-Temporal Resolution Regression	What / Why / How / Use in project
6	Validation Trap และ Metrics	What / Why / How / Use in project
7	Variable-Lag Causality	What / Why / How / Use in project
8	VL-Granger Causality	What / Why / How / Use in project
9	Transfer Entropy และ VL-Transfer Entropy	What / Why / How / Use in project
10	Coordination & Leadership / mFLICA	What / Why / How / Use in project
11	LGTD: Local-Global Trend Decomposition	What / Why / How / Use in project
12	Future Directions	What / Why / How / Use in project
13	สรุปภาพรวมทั้งบท + แนวทางทดสอบ/ทำโปรเจกต์	What / Why / How / Use in project

แก่นของสไลด์ทั้งชุด: เริ่มจากการถามว่า “อะไรจะเกิดขึ้นต่อไป” แล้วขยับไปถามว่า “ทำไมถึงเกิด”, “สัญญาณประกอบจากอะไร”, และ “ใครนำใคร” ซึ่งทำให้ Time Series เป็นเครื่องมือวิเคราะห์ความสัมพันธ์ที่ซ่อนอยู่ในเวลา ไม่ใช่แค่การลากเส้นทำนายอนาคต

1. ภาพรวม Time Series Analysis



ภาพจากสไลด์หน้า 58: The Time Series Ecosystem - Prediction, Causality, Structure, Coordination

หัวข้อนี้คืออะไร

การวิเคราะห์ Time Series คือการวิเคราะห์ข้อมูลที่เรียงตามเวลา เช่น ยอดขายรายวัน โหลดไฟรายชั่วโมง ราคาหุ้น อุณหภูมิ ข้อมูล sensor ในโรงงาน หรือพิกัด GPS ของสัตว์ในแต่ละเวลา จุดสำคัญคือข้อมูลหนึ่งจุดไม่ได้เป็นอิสระจากจุดอื่น เพราะอดีตมักมีโครงสร้างบางอย่างที่ช่วยอธิบายปัจจุบันและอนาคตได้

ใช้ทำอะไร

ใช้เพื่อพยากรณ์อนาคต หาเหตุผลเชิงเวลา แยกองค์ประกอบของสัญญาณ และวิเคราะห์ความสัมพันธ์แบบนำตามในระบบที่มีหลายตัวแปรหรือหลาย entity เช่น โรงงานหลายแห่ง sensor หลายตัว หรือคน/สัตว์หลายตัวที่เคลื่อนที่พร้อมกัน

แนวคิดสำคัญ

- Time Series ต้องรักษาลำดับเวลาเสมอ เพราะลำดับก่อนหลังคือข้อมูลสำคัญ
- Forecasting ตอบคำถาม "What will happen?" แต่ไม่พอสำหรับคำถาม "Why did it happen?"
- การวิเคราะห์เชิงลึกต้องดูทั้ง prediction, causality, structure และ coordination
- สไลด์วาง Time Series เป็น ecosystem ไม่ใช่โมเดลเดียว

ควรทำอะไรเป็นพิเศษ

จำให้ได้: Time Series Analysis = การใช้โครงสร้างของเวลาเพื่อเข้าใจสิ่งที่เกิดขึ้น เหตุผลที่เกิด โครงสร้างของสัญญาณ และความสัมพันธ์แบบใครนำใคร

ตัวอย่างการใช้งานจริง

- Power-load prediction: ทำนายโหลดไฟของโรงงานชั่วโมงถัดไป
- Supply chain: วิเคราะห์ว่าความล่าช้าจาก supplier หนึ่งส่งผลต่ออีกจุดเมื่อไร
- Stock market: ดูว่าหุ้นตัวใดนำการเคลื่อนไหวของอีกตัว
- Animal movement: วิเคราะห์ผู้นำฝูงจาก GPS time series

จุดที่มักสับสน

- คิดว่า Time Series คือ forecasting อย่างเดียว
- คิดว่า correlation ที่เกิดพร้อมกันคือ causality
- ใช้ random split เหมือนข้อมูลตารางทั่วไป
- เลือกโมเดลซับซ้อนโดยไม่ดูความเหมาะสมของข้อมูล

เทคนิคทำความเข้าใจง่าย ๆ

ให้คิดว่า Time Series เหมือนการดูวิดีโอ ไม่ใช่ภาพนิ่ง จุดสำคัญไม่ได้อยู่แค่ค่าของข้อมูล แต่อยู่ที่ลำดับว่าอะไรเกิดก่อนอะไรตามหลัง และ pattern ซ้ำอย่างไร


ถ้าเอาไปสอบควรตอบอย่างไร

คำตอบแนวสอบ: Time Series Analysis คือการวิเคราะห์ข้อมูลที่เรียงตามเวลา โดยใช้ temporal structure เพื่อพยากรณ์ อธิบาย แยกองค์ประกอบ และวิเคราะห์ความสัมพันธ์แบบนำ-ตามในระบบ ข้อมูลอดีตจึงสำคัญต่อการเข้าใจอนาคต แต่ต้องระวังไม่ตีความ correlation เป็น causation

ถ้าเอาไปทำโปรเจกต์ควรใช้ตรงไหน

เริ่มโปรเจกต์ด้วยการระบุให้ชัดว่าโจทย์เป็น forecasting, causality, decomposition หรือ coordination เพราะแต่ละโจทย์ใช้วิธีและการประเมินต่างกัน

2. Four Questions of Signal Analysis



ภาพจากสไลด์หน้า 2: Four Questions of Signal Analysis - กรอบคิด 4 คำถามหลักของ Time Series

คำถาม	เครื่องมือหลัก	ความหมาย	ตัวอย่างในโรงงาน
What will happen?	Forecasting / Prediction	ทำนายค่าหรือเหตุการณ์ในอนาคต	ชั่วโมงหน้าจะใช้ไฟเท่าไร
Why did it happen?	Causality	หาว่าตัวแปรใดมีข้อมูลนำหรือเป็นเหตุเชิงทำนายต่ออีกตัว	โหลตไฟเพิ่มเพราะอุณหภูมิหรือ shift การผลิต
How is the signal built?	Decomposition	แยก trend, seasonality, noise หรือ repeating structure	โหลตไฟมี pattern รายวัน/รายสัปดาห์แค่ไหน
Who is leading whom?	Coordination	หาผู้นำ/ผู้ตามในระบบหลาย entity	factory หรือ machine ไตเริ่มเปลี่ยนก่อน

หัวข้อนี้คืออะไร

Four Questions of Signal Analysis คือกรอบคิดในการตั้งคำถามกับสัญญาณตามเวลา แทนที่จะถามแค่ว่าอนาคตคืออะไร สไลด์แบ่งเป็น 4 คำถามหลัก คือ Predict, Cause, Decompose และ Coordinate

ใช้ทำอะไร

ใช้เป็นแผนที่เลือกเครื่องมือ เช่น ถ้าต้องการทำนายใช้ forecasting model ถ้าต้องการหาเหตุผลใช้ causality
ถ้าต้องการเข้าใจองค์ประกอบของข้อมูลใช้ decomposition และถ้าต้องการวิเคราะห์หลายตัวที่เคลื่อนหรือเปลี่ยนแปลงตามกันใช้ coordination

แนวคิดสำคัญ

- Predict = ตอบ What
- Cause = ตอบ Why
- Decompose = ตอบ How
- Coordinate = ตอบ Who leads whom
- การตั้งคำถามถูกช่วยป้องกันการเลือกโมเดลผิด

ควรจำอะไรเป็นพิเศษ

จำให้ได้: จำคู่คำถามให้ได้: What = Forecasting, Why = Causality, How = Decomposition, Who = Coordination

ตัวอย่างการใช้งานจริง

- ยอดขาย: forecast ยอดขายเดือนหน้า, cause จาก promotion, decompose seasonal sale, coordinate สาขาไหนนำยอดขาย
- IoT: forecast sensor failure, cause จาก pressure, decompose noise, coordinate machine behavior

จุดที่มักสับสน

- เอา feature importance จาก forecasting model ไปสรุปว่าเป็นเหตุจริงทันที
- ใช้ decomposition แล้วคิดว่าได้ causal explanation ทั้งหมด
- คิดว่า leader ใน coordination คือคนที่อยู่ตำแหน่งหน้าสุดเสมอ

เทคนิคทำความเข้าใจง่าย ๆ

ให้จำเป็น 4 เลนส์: หมอดู = forecast, นักสืบ = causality, ช่างแยกชิ้นส่วน = decomposition, คนดูทีม = coordination


ถ้าเอาไปสอบควรตอบอย่างไร

คำตอบแนวสอบ: Four Questions of Signal Analysis เป็นกรอบสำหรับวิเคราะห์ Time Series ผ่าน 4 มุม คือ forecasting เพื่อตอบอนาคต, causality เพื่อตอบเหตุผล, decomposition เพื่อดูโครงสร้าง และ coordination เพื่อดูผู้นำ/ผู้ตาม

ถ้าเอาไปทำโปรเจกต์ควรใช้ตรงไหน

ใช้ตอนเขียน problem statement และเลือก methodology ในรายงาน/โปรเจกต์

3. Anatomy of a Signal: Trend, Seasonality, Noise



ภาพจากสไลด์หน้า 3: Anatomy of a Signal - แยกสัญญาณเป็น Trend, Seasonality และ Noise

Observed Signal = Trend + Seasonality + Noise

องค์ประกอบ	ความหมาย	ตัวอย่าง	คำถามที่ใช้ตรวจ
Trend	ทิศทางระยะยาว เช่น เพิ่ม ลด หรือคงที่	ยอดขายเติบโตขึ้นทุกเดือน	ภาพรวมขึ้นหรือลงไหม
Seasonality	รูปแบบที่เกิดซ้ำตามคาบเวลา	ขายดีวันศุกร์หรือช่วงสิ้นเดือน	มี pattern วนซ้ำไหม
Noise	ความผันผวนสุ่มหรือส่วนที่เหลือหลังอธิบายโครงสร้างหลัก	ยอดขายตกเพราะฝนตกหนักวันเดียว	ส่วนไหนยังอธิบายไม่ได้

หัวข้อนี้คืออะไร

Anatomy of a Signal คือการมอง Time Series เป็นการรวมกันขององค์ประกอบสำคัญ ได้แก่ trend, seasonality และ noise โดย trend คือทิศทางระยะยาว seasonality คือรูปแบบซ้ำ และ noise คือความแปรปรวนที่เหลือ

ใช้ทำอะไร

ใช้เพื่อทำความเข้าใจข้อมูลก่อนสร้างโมเดล ช่วยเลือก preprocessing, feature engineering, decomposition และวิธี forecasting ที่เหมาะสม

แนวคิดสำคัญ

- สัญญาณจริงมักไม่ใช่เส้นเดียวที่ไร้โครงสร้าง แต่เป็นผลรวมของหลายองค์ประกอบ
- Trend ช่วยบอกภาพใหญ่, seasonality ช่วยบอกจังหวะซ้ำ, noise ช่วยบอกส่วนที่ไม่แน่นอน
- การแยกองค์ประกอบทำให้ตีความง่ายและมักช่วยให้โมเดลพยากรณ์ดีขึ้น

ควรจำอะไรเป็นพิเศษ

จำให้ได้: Trend = ภาพใหญ่, Seasonality = วงซ้ำ, Noise = ส่วนที่อธิบายยากหรือสุ่ม

ตัวอย่างการใช้งานจริง

- ยอดใช้ไฟโรงงานมี trend เพิ่มจากกำลังผลิตที่สูงขึ้น
- ยอดขายมี seasonality ช่วง payday
- sensor มี noise จากเครื่องจักรสั่นหรือสัญญาณรบกวน

จุดที่มักสับสน

- คิดว่า spike ทุกอันเป็น noise ทั้งที่บาง spike อาจเป็น event สำคัญ
- สับสนระหว่าง trend กับ seasonality เมื่อ seasonality มี amplitude เปลี่ยน
- คิดว่า seasonality ต้องเป็นรายปีเท่านั้น ทั้งที่อาจเป็นรายชั่วโมง/รายวัน/รายสัปดาห์

เทคนิคทำความเข้าใจง่าย ๆ

ลอง plot ข้อมูลแล้วไล่ถาม 3 คำถาม: โดยรวมขึ้น/ลงไหม, มีจังหวะวนไหม, ส่วนที่เหลือมี spike หรือ noise ไหม


ถ้าเอาไปสอบควรตอบอย่างไร

คำตอบแนวสอบ: สัญญาณ Time Series มักประกอบด้วย trend, seasonality และ noise
การแยกองค์ประกอบเหล่านี้ช่วยให้เข้าใจโครงสร้างของข้อมูลและเลือกโมเดลที่เหมาะสม


ถ้าเอาไปทำโปรเจกต์ควรใช้ตรงไหน

ใช้ในขั้น EDA และ preprocessing ก่อนทำ forecasting หรือ anomaly detection


4. Demand Forecasting



ภาพจากสไลด์หน้า 5: Forecasting quality กับต้นทุนทางธุรกิจจากการทำนายผิด



ภาพจากสไลด์หน้า 6: Forecasting Optimization Engine - เลือกโมเดลตามความซับซ้อนของข้อมูล



ภาพจากสไลด์หน้า 12: Factory Power Load Prediction - ตัวอย่างโจทย์ใช้งานจริง

โมเดล	เหมาะกับข้อมูลแบบไหน	จุดเด่น	ข้อควรระวัง
ARIMA / ETS	Univariate, pattern ไม่ซับซ้อนมาก, ต้องการ baseline	ดี ความง่าย ใช้เร็ว	อาจไม่ดีเมื่อมีหลายตัวแปรหรือ nonlinear สูง
Prophet	มี seasonality/holiday/change points ชัด	ใช้ง่ายและดีสำหรับ business calendar	ต้องระวัง holiday/seasonality ที่ไม่เกี่ยวข้องจริง
LSTM / DeepAR	ข้อมูลเยอะ มีหลายตัวแปรและ nonlinear	จับ pattern ซับซ้อนได้	ต้องใช้ข้อมูลมากและ validate ระวัง overfit
Transformer / Foundation Models	series ยาวหรือหลาย series และต้องการ baseline สมัยใหม่	เรียน long-range dependency ได้ดี	อาจดี ความยากและต้องเทียบ baseline

หัวข้อนี้คืออะไร

Demand Forecasting คือการพยากรณ์ความต้องการในอนาคต เช่น ยอดขาย จำนวนสินค้า วัตถุดิบ หรือโหลดไฟฟ้า
 สไลด์ยกตัวอย่าง factory power-load prediction ที่ต้องทำนายโหลดไฟเพื่อกำหนด generator
 และการดำเนินงานต่อเนื่อง

ใช้ทำอะไร

ใช้เพื่อกำหนดทรัพยากร ลด stockout ลด overstock ลด waste และเพิ่ม operational efficiency
 เพราะการทำนายต่ำเกินไปและสูงเกินไปล้วนมีต้นทุน

แนวคิดสำคัญ

- Forecast quality เป็นตัวแทนของ operational efficiency
- Under-prediction และ over-prediction อาจมีต้นทุนไม่เท่ากัน
- ต้องเลือก model complexity ให้ตรงกับ data richness
- เริ่มจาก baseline ก่อน แล้วค่อยเพิ่มความซับซ้อน

ควรจำอะไรเป็นพิเศษ

จำให้ได้: โมเดลที่ดีที่สุดไม่ใช่โมเดลที่ล้ำที่สุด แต่คือโมเดลที่เหมาะสมกับข้อมูล ธุรกิจ และต้นทุนของความผิดพลาด

ตัวอย่างการใช้งานจริง

- ทำนายโหลดไฟชั่วโมงถัดไปจาก historical load, temperature, hour-of-day, day-of-week
- ทำนายยอดขายรายวันจากยอดขายอดีต โปรโมชัน และวันหยุด
- ทำนาย demand วัตถุประสงค์เพื่อป้องกัน rush order

จุดที่มักสับสน

- คิดว่า deep learning ต้องชนะเสมอ
- เลือก metric ไม่ตรงกับต้นทุนจริง
- พยากรณ์ได้ดีแต่ deploy ไม่ได้เพราะ data ในอนาคตที่ใช้เป็น feature ไม่มีจริงตอนใช้งาน

เทคนิคทำความเข้าใจง่าย ๆ

คิดเหมือนการเตรียมสินค้า: ทำนายน้อยไปของหมด ทำนายมากไปของเหลือ ทำนายพอดีคือต้นทุนต่ำและบริการดี


ถ้าเอาไปสอบควรตอบอย่างไร

คำตอบแนวสอบ: Demand Forecasting คือการทำนายความต้องการอนาคตเพื่อใช้วางแผนทรัพยากร โดยควรเลือกโมเดลตามความซับซ้อนของข้อมูล เช่น ARIMA/ETS สำหรับ baseline, Prophet สำหรับ seasonality ชัด, และ LSTM/Transformer สำหรับข้อมูลหลายตัวแปรที่ซับซ้อน


ถ้าเอาไปทำโปรเจกต์ควรใช้ตรงไหน

เหมาะเป็นแกนหลักของโปรเจกต์ prediction เช่น sales forecast, power-load forecast, inventory demand forecast และ server traffic forecast

5. Multi-Temporal Resolution Regression




ภาพจากสไลด์หน้า 8: Multi-Temporal Resolution Architecture - รวมหลายช่วงเวลาเป็น feature space



ภาพจากสไลด์หน้า 14: Temporal Complexity - โรงงานแต่ละแห่งมีจังหวะเวลาไม่เหมือนกัน

Solution: Multi-Temporal Resolution Regression




Instead of a single historical window, time is explicitly modeled at multiple resolutions simultaneously, allowing the algorithm to weight short, medium, and long-term histories differently for every single prediction.

NotebookLM

ภาพจากสไลด์หน้า 16: Multi-Temporal Resolution Regression - short, weekly, monthly windows

Constructing the Unified Feature Matrix



NotebookLM

ภาพจากสไลด์หน้า 17: Unified Feature Matrix - การ concatenate feature จากหลาย factory และหลาย scale

$$Y(t) = f(X_{2d}, X_{wk}, X_{mo})$$

Temporal Window	Feature ตัวอย่าง	จับ pattern อะไร	เหมาะกับสถานการณ์
2-Day / 48h	mean, max, std, recent spike, hour-of-day	แรงกระแทกล่าสุดและ operational momentum	เครื่องจักร downtime, อุณหภูมิกระโดด, shift เปลี่ยน
Weekly / 7d	rolling mean 7d, day-of-week encoding, weekday/weekend	รอบการผลิตรายสัปดาห์	โรงงานมี schedule รายสัปดาห์หรือวันหยุด
Monthly / 30d	rolling mean 30d, seasonal indicators, capacity baseline	baseline และ trend ระยะยาว	demand cycle, quota, fulfillment trend

หัวข้อนี้คืออะไร

Multi-Temporal Resolution Regression คือการสร้าง feature จากหลายช่วงเวลาแล้วรวมกันเป็น feature matrix แทนการบังคับให้โมเดลดูอดีตแค่ window เดียว เช่น 2 วัน, 7 วัน และ 30 วัน

ใช้ทำอะไร

ใช้กับข้อมูลที่มีหลายจังหวะพร้อมกัน เช่น โรงงานหนึ่งตอบสนองรายวัน อีกโรงงานมี pattern รายสัปดาห์ และอีกโรงงานมี quota รายเดือน การใช้ window เดียวจะ flatten ความหลากหลายเหล่านี้

แนวคิดสำคัญ

- แต่ละ factory/site อาจมี heartbeat ต่างกัน
- Node-level slicing คือแยก feature ของแต่ละโรงงานตามหลาย scale
- Global concatenation คือรวม feature ทั้งหมดให้โมเดลเห็น ecosystem พร้อมกัน
- โมเดลเรียนเองว่า scale ไหนสำคัญผ่าน feature importance หรือ weights

ควรจำอะไรเป็นพิเศษ

จำให้ได้: อย่าบังคับ single lookback window ถ้าข้อมูลมีหลาย rhythm ให้สร้าง multi-scale features แล้วให้โมเดลเลือกเอง

ตัวอย่างการใช้งานจริง

- โหลดไฟโรงงาน A ขึ้นลงตามอุณหภูมิรายวัน แต่โรงงาน B ทำงานตาม schedule รายสัปดาห์
- ยอดขายร้านค้าดู 7 วันเพื่อจับ weekday และ 30 วันเพื่อจับ trend
- traffic เว็บไซต์ 1 ชั่วโมง, 24 ชั่วโมง และ 7 วันเพื่อจับ spike/day/week pattern

จุดที่มักสับสน

- สับสน Multi-temporal กับ Multi-step forecasting
- เอาข้อมูลหลาย window มารวมโดยไม่ระวัง leakage
- คิดว่า window ยาวกว่าดีเสมอ ทั้งที่อาจตอบสนอง spike ชั่ว

เทคนิคทำความเข้าใจง่าย ๆ

เปรียบเทียบเหมือนวินิจฉัย: ดูอาการ 2 วันล่าสุด ดู pattern ในสัปดาห์นี้ และดูประวัติ 1 เดือนเพื่อเข้าใจทั้งระยะสั้น กลาง และยาว


ถ้าเอาไปสอบควรตอบอย่างไร

คำตอบแนวสอบ: Multi-Temporal Resolution Regression คือการสร้าง feature จากหลาย time windows เช่น 2-day, weekly และ monthly แล้ว concatenate เป็น feature matrix เพื่อให้โมเดลเรียนรู้ว่า temporal scale ใดสำคัญต่อ target

ถ้าเอาไปทำโปรเจกต์ควรใช้ตรงไหน

ใช้ทำ feature engineering ใน forecasting project โดยเฉพาะข้อมูลที่มีหลาย seasonality หรือหลาย entity

6. Validation Trap และ Metrics



ภาพจากสไลด์หน้า 9: Validation Trap - ห้าม random split ใน Time Series

Golden Rule 2: Metric Selection is Policy Definition

Metric	Formula Intuition	When to Use It
Mean Absolute Error (MAE)	Average absolute error; symmetric penalty.	The default baseline. Easy to explain to business stakeholders.
Root Mean Square Error (RMSE)	Squares the errors before averaging, heavily penalizing large misses.	Use when big misses cost disproportionately more than small misses (e.g., severe power blackouts).
Mean Absolute Percentage Error (MAPE)	Error as a percentage of actuals.	Cross-factory or cross-product comparison where scales vary drastically.

© NotebookLM

ภาพจากสไลด์หน้า 10: Metric Selection - MAE, RMSE, MAPE และความหมายเชิงนโยบาย

Metric	สูตรโดยสัญชาตญาณ	เหมาะเมื่อไร	ข้อควรระวัง
MAE	เฉลี่ย ค่าจริง - ค่าทำนาย	ใช้เป็น baseline อธิบายง่าย	ไม่ลงโทษ error ใหญ่หนักเท่า RMSE
RMSE	ยกกำลังสอง error ก่อนเฉลี่ย แล้วถอดราก	ใช้เมื่อ miss ใหญ่มีต้นทุนสูง เช่น blackout	ไวต่อ outlier มากกว่า MAE
MAPE	error เป็นเปอร์เซ็นต์ของค่าจริง	เปรียบเทียบข้ามโรงงาน/สินค้าที่ scale ต่างกัน	มีปัญหาเมื่อ actual ใกล้ศูนย์

หัวข้อนี้คืออะไร

Validation Trap คือกับดักการประเมินโมเดล Time Series ผิด โดยเฉพาะการ random split ทำให้ข้อมูลอนาคตรั่วเข้า train set เพราะ Time Series ไม่ใช่ iid data

ใช้ทำอะไร

ใช้เพื่อประเมินโมเดลให้ใกล้เคียงการใช้งานจริง ใน production เราใช้ข้อมูลอดีตทำนายอนาคต ดังนั้น validation ก็ต้อง split ตามเวลา

แนวคิดสำคัญ

- ห้าม random split สำหรับ Time Series forecasting
- ใช้ chronological split, expanding window หรือ walk-forward validation
- Metric selection คือ policy definition เพราะบอกว่าเราลงโทษความผิดพลาดแบบไหน
- ต้องถามว่าตอน deploy โมเดลมีสิทธิ์เห็น feature นี้จริงไหม

ควรจำอะไรเป็นพิเศษ

จำให้ได้: Golden Rule: split ตามเวลาเสมอ และเลือก metric ตามต้นทุนธุรกิจ ไม่ใช่เลือกเพราะตัวเลขสวย

ตัวอย่างการใช้งานจริง

- โหลดไฟ: ใช้ RMSE หาก error ใหญ่ทำให้ blackout
- ยอดขายหลาย product: ใช้ MAPE เพื่อเทียบ scale
- รายงานธุรกิจ: ใช้ MAE เพื่ออธิบายง่าย

จุดที่มักสับสน

- คิดว่า random split accuracy สูงคือโมเดลดี
- ใช้ MAPE กับข้อมูลที่มีศูนย์หรือใกล้ศูนย์
- ดู metric เดียวโดยไม่ดู plot predicted vs actual

เทคนิคทำความเข้าใจง่าย ๆ

ทุกครั้งที่สร้าง feature ให้ถามว่า “เวลาทำนายจริง ณ เวลานั้น เรารู้ข้อมูลนี้แล้วหรือยัง” ถ้ายังไม่รู้ แปลว่า leakage


ถ้าเอาไปสอบควรตอบอย่างไร

คำตอบแนวสอบ: Validation Trap คือการประเมิน Time Series ด้วย random split ทำให้ future information leakage วิธีที่ถูกคือ split ตามเวลา เช่น expanding window หรือ walk-forward validation และเลือก metrics เช่น MAE, RMSE, MAPE ตาม business cost


ถ้าเอาไปทำโปรเจกต์ควรใช้ตรงไหน

ใช้ในขั้น model evaluation และ experiment design ต้องมี backtesting หลายช่วงเวลาและรายงาน metric พร้อมกราฟ

7. Variable-Lag Causality




ภาพจากสไลด์หน้า 21: The Limits of Forecasting - จาก What ไปสู่ Why



ภาพจากสไลด์หน้า 23: Predictive Precedence vs Physical Intervention

Fixed vs. Arbitrary lag follower



ภาพจากสไลด์หน้า 28: Fixed vs Arbitrary Lag Follower - ปัญหา lag ที่เปลี่ยนตามเวลา

หัวข้อนี้คืออะไร

Variable-Lag Causality คือแนวคิด causality เชิงเวลาแบบยอมให้ delay ระหว่าง cause และ effect เปลี่ยนไปตามเวลา ต่างจากวิธี fixed-lag ที่สมมติว่า X ส่งผลต่อ Y หลังจำนวนเวลาคงที่เสมอ

ใช้ทำอะไร

ใช้หา lead-lag relationship ในโลกจริงที่ delay ยืดหด เช่น supply chain delay, sensor propagation, stock lead-lag หรือ behavior ของคน/สัตว์ในกลุ่ม

แนวคิดสำคัญ

- Standard Granger มักสมมติ lag คงที่
- Real-world time series มัก non-stationary และ delay อาจ expand/compress
- Dynamic Time Warping หรือ DTW ใช้ align สัญญาณที่ยืดหดตามเวลา
- Causality ในที่นี้เป็น predictive precedence ไม่ใช่ physical intervention เต็มรูปแบบ

ควรจำอะไรเป็นพิเศษ

จำให้ได้: Variable lag = effect ตาม cause ด้วยระยะเวลาที่เปลี่ยนได้ ไม่ใช่ตามหลังเท่ากันทุกครั้ง

ตัวอย่างการใช้งานจริง

- Supplier ต้นน้ำ delay ส่งผลถึงโรงงานปลายทางไม่เท่ากันทุกครั้ง
- เครื่องจักรหนึ่งเริ่มสั่นก่อน อีกเครื่องสั่นตาม แต่บางรอบตามเร็ว บางรอบตามช้า
- คนเดินนำฝูง บางช่วงผู้ตามตอบสนองเร็ว บางช่วงช้า

จุดที่มักสับสน

- คิดว่า variable-lag causality พิสูจน์เหตุผลเชิงฟิสิกส์ 100%
- คิดว่า lag เปลี่ยนได้แปลว่าเลือก lag ตามใจ
- ละเลย confounder ที่อาจทำให้ X และ Y คล้ายกัน

เทคนิคทำความเข้าใจง่าย ๆ

นึกถึงคนเดินตามกัน ถ้าระยะตามคงที่ตลอดคือ fixed lag แต่ถ้าบางช่วงตามเร็ว บางช่วงตามช้าคือ variable lag


ถ้าเอาไปสอบควรตอบอย่างไร

คำตอบแนวสอบ: Variable-Lag Causality คือการวิเคราะห์ความสัมพันธ์เชิงนำ-ตามที่มี delay ระหว่าง cause และ effect เปลี่ยนได้
เหมาะกับ time series จริงที่ non-stationary และมี lag ยืดหด โดยมักใช้ DTW เป็นกลไก alignment


ถ้าเอาไปทำโปรเจกต์ควรใช้ตรงไหน

ใช้ในโปรเจกต์ที่ต้องการ propagation หรือ influence แบบ delay ไม่แน่นอน เช่น sensor network, supply chain และ stock markets

8. VL-Granger Causality



ภาพจากสไลด์หน้า 25: VAR Mechanism - Restricted/Unrestricted Models ใน Granger Causality



ภาพจากสไลด์หน้า 30: VL-Granger Causality - ใช้ DTW เพื่อ align delay ที่ยืดหด

ส่วนประกอบ	ความหมาย	สิ่งที่ต้องจำ
------------	----------	---------------

Restricted model	ใช้อัตถของ Y เพื่อทำนายอนาคต Y	baseline ของการทำนาย Y
Unrestricted model	ใช้อัตถของ Y + อัตถของ X	ถ้าดีขึ้นมาก แสดงว่า X มีข้อมูลเพิ่ม
F-test	ตรวจว่าการลด error มีนัยสำคัญไหม	ใช้เป็น decision criterion
BICDiffRatio	วัด causal strength 0 ถึง 1 โดยคำนึง complexity penalty	ใกล้ 1 = evidence แข็งแรงกว่า
DTW alignment	จัดแนว X และ Y เมื่อ lag ยึดหด	สะพานสู่ variable-lag causality

```
library(VLTimeCausality)
TS <- SimpleSimulationVLtimeseries()
out <- VLGrangerFunc(Y = TS$Y, X = TS$X)
out$XgCsY      # TRUE/FALSE
out$BICDiffRatio # 0 to 1
```

หัวข้อนี้คืออะไร

VL-Granger Causality คือการขยาย Granger causality ให้รองรับ variable lag โดยใช้ DTW alignment ก่อน แล้วทดสอบว่าอัตถของ X ช่วยทำนายอนาคตของ Y เพิ่มขึ้นจากการใช้อัตถของ Y อย่างเดียวหรือไม่

ใช้ทำอะไร

ใช้ตรวจว่า X มี predictive causal influence ต่อ Y ในกรณีที่ delay ระหว่าง X กับ Y ไม่คงที่

แนวคิดสำคัญ

- หลักของ Granger คือ predictive precedence: knowing X history helps forecast Y
- VL-Granger เพิ่ม alignment เพื่อรับมือ lag ที่ยืดหด
- BICDiffRatio ช่วยวัด strength พร้อมลงโทษ complexity
- เหมาะกับความสัมพันธ์ค่อนข้าง linear และต้องการ computation เร็ว

ควรจำอะไรเป็นพิเศษ

จำให้ได้: ถ้ามว่า “รู้อัตถของ X เพิ่มจากอัตถของ Y แล้วทำนาย Y ได้ดีขึ้นอย่างมีนัยสำคัญไหม” ถ้าใช่ X VL-Granger-causes Y

ตัวอย่างการใช้งานจริง

- Industrial IoT: sensor pressure นำ vibration

- Supply chain: supplier delay นำ production delay
- Finance: asset A นำ asset B ด้วย lag ไม่คงที่

จุดที่มักสับสน

- เข้าใจว่า Granger causality เท่ากับ causal intervention
- ใช้ค่า BICDiffRatio สูงแล้วไม่ดู p-value หรือ validation
- ไม่ตรวจ stationarity/normalization/quality ของ data

เทคนิคทำความเข้าใจง่าย ๆ

คิดเป็นการแข่งขันของสองโมเดล: โมเดล A รู้แค่ประวัติ Y ส่วนโมเดล B รู้ประวัติ Y และ X ถ้า B ชนะอย่างมีนัยสำคัญ แปลว่า X ให้ข้อมูลที่มีประโยชน์


ถ้าเอาไปสอบควรตอบอย่างไร

คำตอบแนวสอบ: VL-Granger Causality ใช้ DTW align time series เพื่อรองรับ lag ที่เปลี่ยนได้ แล้วเปรียบเทียบ restricted และ unrestricted model ถ้าเพิ่ม X แล้วลด forecasting error อย่างมีนัยสำคัญ และ BICDiffRatio สูง แสดงว่า X มี predictive causal effect ต่อ Y

ถ้าเอาไปทำโปรเจกต์ควรใช้ตรงไหน

ใช้สร้าง causal graph ระหว่าง sensor, factory, stock หรือ node ต่าง ๆ ในระบบ

9. Transfer Entropy และ VL-Transfer Entropy



ภาพจากสไลด์หน้า 31: Transfer Entropy - directed information flow ใน Time Series

วิธี	เหมาะกับ	ข้อดี	ข้อควรระวัง
VL-Granger	linear relationships, computation เร็ว	อธิบายง่าย ใช้ F-test/BIC	อาจพลาด nonlinear dependency
VL-Transfer Entropy	nonlinear/complex interactions	model-free, information-theoretic	คำนวณและเลือก estimator/parameter ยากกว่า

หัวข้อนี้คืออะไร

Transfer Entropy คือวิธีวัดการไหลของข้อมูลแบบมีทิศทางจาก Time Series หนึ่งไปยังอีกตัว โดยดูว่าอดีตของ X ช่วยลด uncertainty ของอนาคต Y ได้มากกว่าการใช้อดีตของ Y เองหรือไม่ ส่วน VL-Transfer Entropy ขยายให้รองรับ variable lag ผ่าน DTW

ใช้ทำอะไร

ใช้เมื่อความสัมพันธ์ซับซ้อนหรือ nonlinear เช่น brain connectivity, sensor network, social influence หรือ biological movement

แนวคิดสำคัญ

- TE เป็น asymmetric: $X \rightarrow Y$ ไม่จำเป็นต้องเท่ากับ $Y \rightarrow X$
- วัด information flow ไม่ใช่แค่ correlation
- VL-TE รองรับ delay ที่เปลี่ยนตามเวลา
- เป็น model-free และไม่ต้องสมมติรูปแบบ distribution แบบ linear model

ควรจำอะไรเป็นพิเศษ

จำให้ได้: VL-Granger สำหรับ linear/เร็ว, VL-TE สำหรับ nonlinear/ซับซ้อน

ตัวอย่างการใช้งานจริง

- fMRI: region A ส่งข้อมูลไป region B
- IoT: sensor หนึ่งมี nonlinear influence ต่ออีก sensor
- ตลาดการเงิน: ความสัมพันธ์ระหว่างสินทรัพย์อาจไม่เป็นเส้นตรง

จุดที่มักสับสน

- คิดว่า TE คือ correlation ที่มีทิศทาง ทั้งที่ TE วัด uncertainty reduction
- ลืมว่า TE ต้องการข้อมูลมากพอ
- ดีความ information flow เป็น intervention causality ตรง ๆ

เทคนิคทำความเข้าใจง่าย ๆ

ถามง่าย ๆ ว่า “X บอกไปอะไรเกี่ยวกับอนาคตของ Y ที่อดีตของ Y เองยังบอกไม่ได้ไหม”


ถ้าเอาไปสอบควรตอบอย่างไร

คำตอบแนวสอบ: Transfer Entropy วัด directed information flow จาก X ไป Y โดยดูว่า X ช่วยลด uncertainty ของอนาคต Y ได้หรือไม่ และ VL-Transfer Entropy ขยายแนวคิดนี้ด้วย variable lags ผ่าน DTW เหมาะกับ nonlinear dependencies


ถ้าเอาไปทำโปรเจกต์ควรใช้ตรงไหน

ใช้เมื่อโปรเจกต์ต้องการ causal/influence analysis แต่คาดว่าความสัมพันธ์ไม่เป็น linear

10. Coordination & Leadership / mFLICA



ภาพจากสไลด์หน้า 38: Beyond Forecasting - Group Dynamics และ mFLICA



ภาพจากสไลด์หน้า 42: Leader & Faction Detection - following network และนิยาม leader

คำศัพท์	ความหมาย	ตัวอย่าง
Node	individual/entity ในระบบ	ลิงแต่ละตัว, sensor แต่ละตัว, หุ่นแต่ละตัว
Edge $i \rightarrow j$	i follows j	คน/สัตว์/เครื่องจักร i เคลื่อนหรือเปลี่ยนตาม j
Leader	node ที่คนอื่นตามมาก แต่ตัวเองไม่ค่อยตามใคร	ตัวนำฝูงหรือหุ่นที่นำ sector
Faction	กลุ่มที่ตาม leader เดียวกัน	กลุ่มย่อยในฝูงหรือ cluster ของสินทรัพย์
Dynamic network	เครือข่ายที่เปลี่ยนตามเวลา	leadership เปลี่ยนได้ระหว่างเหตุการณ์

```
install.packages("mFLICA")
library(mFLICA)
result <- mFLICA(mFLICA::TS)
result$leaders
result$factions
```

หัวข้อนี้คืออะไร

mFLICA หรือ Multi-Faction Leadership Inference from Coordinated Activities เป็น framework สำหรับหาผู้นำผู้ตาม และ faction จาก multidimensional time series โดยไม่จำเป็นต้องมี interaction data โดยตรง ใช้ข้อมูลการเคลื่อนหรือพฤติกรรมตามเวลาเป็นหลัก

ใช้ทำอะไร

ใช้วิเคราะห์ group dynamics เช่น ฝูงสัตว์ social network ตลาดการเงิน robot swarm หรือหลาย machine/factory ที่มีพฤติกรรมเปลี่ยนตามกัน

แนวคิดสำคัญ

- ใช้ DTW ตรวจ pairwise following relation
- สร้าง directed following network ในแต่ละช่วงเวลา
- Leader = high in-degree และ zero/low out-degree
- Faction = กลุ่มที่ตาม leader เดียวกัน
- หลาย faction สามารถเกิดพร้อมกันได้

ควรทำอะไรเป็นพิเศษ

จำให้ได้: mFLICA ตอบคำถาม “ใครนำใคร” ในระบบหลาย entity ไม่ใช่แค่ causality แบบคู่ $X \rightarrow Y$

ตัวอย่างการใช้งานจริง

- Baboon GPS collar: หาว่าตัวใดนำฝูง
- ตลาดหุ้น: หาหุ้นที่เป็น leader ของกลุ่ม
- โรงงาน: หา machine/site ที่เริ่มเปลี่ยน pattern ก่อน

จุดที่มักสับสน

- คิดว่า leader คือ entity ที่อยู่ด้านหน้าเสมอ
- คิดว่าระบบมี leader เดียวเท่านั้น
- สับสน coordination กับ causality แบบคู่

เทคนิคทำความเข้าใจง่าย ๆ

นึกถึงกลุ่มคนเดินในห้าง คนที่เริ่มแล้วคนอื่นเลี้ยวตามบ่อย ๆ คือ leader ส่วนกลุ่มที่ตามคนเดียวกันคือ faction


ถ้าเอาไปสอบควรตอบอย่างไร

คำตอบแนวสอบ: mFLICA คือ framework สำหรับวิเคราะห์ leadership และ coordination ใน multivariate time series โดยใช้ DTW หา following relations สร้าง directed network แล้วหา leader จาก high in-degree และ zero out-degree รวมถึงหา faction จากกลุ่มผู้ตาม leader เดียวกัน


ถ้าเอาไปทำโปรเจกต์ควรใช้ตรงไหน

ใช้ในโปรเจกต์ที่มีหลาย agent/entity เช่น movement analysis, swarm robotics, financial leader-follower หรือ industrial coordination

11. LGTD: Local-Global Trend Decomposition




ภาพจากสไลด์หน้า 47: LGTD - Local-Global Trend Decomposition



ภาพจากสไลด์หน้า 48: Real-world Seasonality - non-stationary, intermittent, overlapping cycles

The LGTD Paradigm Shift

LGTD eliminates the need for explicit period selection. It automatically identifies and aggregates repeating structures of arbitrary and potentially time-varying scales.




ภาพจากสไลด์หน้า 50: LGTD Paradigm Shift - $y_t = T_t + S_t + R_t$

The Evolution of Decomposition


Feature	Classical (STL / X-11)	LGTD
Seasonal Assumption	Fixed	Season-Length-Free
Period Input	Required / User-specified	Fully Automatic
Drifting Cycles	Degrades / Fails	Seamlessly Supported
Trend Modeling	Rigid	Adaptive (Linear / LOWESS)

LGTD shifts time series decomposition from a manual, trial-and-error tuning process into a fully automated extraction engine.

ภาพจากสไลด์หน้า 51: Evolution of Decomposition - Classical vs LGTD



ภาพจากสไลด์หน้า 52: LGTD Core Capabilities Framework



ภาพจากสไลด์หน้า 53: LGTD Workflow - input series to output components

$$y_t = T_t + S_t + R_t$$

T_t = Global trajectory / trend

S_t = Aggregated repeating structure

R_t = Residual / isolated noise

Feature	Classical STL/X-11	LGTD
Seasonal assumption	Fixed	Season-length-free
Period input	Required / user-specified	Fully automatic
Drifting cycles	Degrades / fails	Seamlessly supported
Trend modelling	Rigid	Adaptive เช่น Linear / LOWESS

หัวข้อนี้คืออะไร

LGTD หรือ Local-Global Trend Decomposition คือวิธีแยกองค์ประกอบ Time Series ที่ไม่ต้องกำหนด seasonal period ล่วงหน้า จุดเด่นคือ season-length-free และรองรับ seasonality ที่ drift, pause/resume หรือซ้อนหลายคาบได้ดีกว่าวิธี classical ที่ period-dependent

ใช้ทำอะไร

ใช้แยกสัญญาณออกเป็น global trend, repeating structure และ residual เพื่อนำไปทำ forecasting, anomaly detection, visualization หรือ preprocessing ให้ deep model

แนวคิดสำคัญ

- ข้อมูลจริงไม่ค่อยทำตาม textbook: seasonality อาจยืด หด หาย หรือซ้อนกัน
- Classical decomposition มักต้องกำหนด period เอง
- LGTD ลด manual trial-and-error ในการเลือก seasonal length
- Residual อาจใช้หา anomaly หรือ event สำคัญ

ควรจำอะไรเป็นพิเศษ

จำให้ได้: LGTD = decomposition แบบไม่ต้องกำหนดความยาวฤดูกาลเอง แยก y_t เป็น $T_t + S_t + R_t$

ตัวอย่างการใช้งานจริง

- เว็บ traffic ที่มี event ทำให้ pattern เปลี่ยน
- sensor โรงงานที่มีรอบเครื่องจักรไม่สม่ำเสมอ

- ยอดขายที่มีหลาย seasonality และ promotion ทำให้ pattern หาย/กลับมา

จุดที่มักสับสน

- คิดว่า LGTD เป็น forecasting model โดยตรง ทั้งที่หลัก ๆ เป็น decomposition/preprocessing
- คิดว่า season-length-free แปลว่าไม่มี seasonality
- มอง residual เป็นขยะ ทั้งที่อาจมี anomaly

เทคนิคทำความเข้าใจง่าย ๆ

คิดว่า LGTD เป็นเครื่องแยกเสียงเพลง: เสียงหลักคือ trend จังหวะซ้ำคือ repeating structure เสียงรบกวนคือ residual แต่ไม่ต้องบอกก่อนว่าจังหวะยาวก็ beat


ถ้าเอาไปสอบควรตอบอย่างไร

คำตอบแนวสอบ: LGTD คือ Local-Global Trend Decomposition ที่แยก time series เป็น global trend, aggregated repeating structure และ residual โดยไม่ต้องกำหนด seasonal period ล่วงหน้า จึงเหมาะกับข้อมูลจริงที่มี drifting cycles, intermittent patterns และ multiple overlapping cycles

ถ้าเอาไปทำโปรเจกต์ควรใช้ตรงไหน

ใช้ก่อน forecasting เพื่อทำ feature/preprocessing หรือใช้ residual สำหรับ anomaly detection

12. Future Directions



ทิศทางอนาคต	ความหมาย	เอาไปต่อยอดโปรเจกต์ได้อย่างไร
Multi-Band VL-Granger	ขยาย causality ไปยัง frequency-domain	ดูว่า causal influence เกิดใน band ความถี่ใด
Foundation models for time series	ใช้ TimeGPT/Chronos เป็น baseline forecasting	เปรียบเทียบกับ ARIMA/Prophet/Deep model ของเรา
LGTD + causal features	ใช้ decomposition ร่วมกับ causal signals	ทำ preprocessing ก่อนเข้า deep model
Online/streaming mFLICA	ตรวจ coordination แบบ real-time	dashboard ตรวจ leader/follower สตในโรงงาน
Cross-domain transfer	ทดสอบ causal structure ข้าม factory/domain	เรียนรู้จากโรงงานหนึ่งแล้วปรับใช้กับอีกโรงงาน

หัวข้อนี้คืออะไร

Future Directions คือแนวทางต่อยอดของ Time Series Analysis จากสไลด์ ได้แก่ causal analysis ใน frequency domain, foundation models, การรวม decomposition กับ causal features, mFLICA แบบ streaming และ cross-domain transfer

ใช้ทำอะไร

ใช้เป็นแนวทางวิจัยหรือโปรเจกต์ขั้นสูง โดยเชื่อม forecasting, causality, decomposition และ coordination เข้าด้วยกัน

แนวคิดสำคัญ

- อนาคตของ Time Series คือ ecosystem ที่รวมหลายเทคนิค
- Foundation model เป็น baseline ได้ แต่ไม่แทน domain knowledge
- Decomposition และ causality ช่วยให้ deep model เข้าใจ structure มากขึ้น
- Real-time coordination สำคัญกับระบบ production

ควรจำอะไรเป็นพิเศษ

จำให้ได้: อย่ามอง Time Series เป็นโมเดลเดี่ยว ให้มองเป็น pipeline ที่รวมหลายเลนส์

ตัวอย่างการใช้งานจริง

- Smart factory dashboard: forecast + causality + LGTD + coordination
- Financial monitoring: lead-lag + decomposition + anomaly alert
- IoT streaming: sensor causal diagnostics แบบ real-time

จุดที่มักสับสน

- คิดว่า foundation model แก้ได้ทุกอย่าง
- คิดว่า causality feature เหมือน feature importance ธรรมดา
- ลืมว่า streaming ต้องแก้ latency และ data drift

เทคนิคทำความเข้าใจง่าย ๆ

วาง pipeline เป็น Raw data -> Decomposition -> Causal/Coordination analysis -> Forecasting -> Real-time decision

ถ้าเอาไปสอบควรตอบอย่างไร

คำตอบแนวสอบ: Future directions ของ Time Series คือการผสม forecasting, causal analysis, decomposition และ coordination เช่น Multi-Band VL-Granger, foundation models, LGTD preprocessing, online mFLICA และ cross-domain transfer

ถ้าเอาไปทำโปรเจกต์ควรใช้ตรงไหน

ใช้สร้างโปรเจกต์ขั้นสูงที่ไม่ใช่แค่ทำนาย แต่บอกเหตุผล โครงสร้าง และความสัมพันธ์ในระบบ

13. สรุปภาพรวมทั้งหมด

มุมมอง	คำถาม	เครื่องมือในสไลด์	ผลลัพธ์ที่ได้
Prediction	What happens next?	Multi-Temporal Regression, ARIMA, Prophet, LSTM/Transformer	ค่าพยากรณ์ เช่น demand/load
Causality	Why does it happen?	VL-Granger, VL-Transfer Entropy	directed influence หรือ causal strength
Structure	How do we see clearly?	LGTD	trend, repeating structure, residual
Coordination	Who is leading whom?	mFLICA	leaders, followers, factions

Mind Map จำทั้งบท

- Raw Time Series
- > Forecasting: ทำนายอนาคต
 - > Causality: หา predictive influence
 - > Decomposition: แยก trend/seasonality/noise
 - > Coordination: หา leader/follower
 - > Decision Support: alert, planning, optimization

Checklist ก่อนทำโปรเจกต์ Time Series

1. นิยาม target ให้ชัด เช่น next-hour load, next-day peak demand หรือ anomaly score
2. ตรวจ temporal granularity เช่น hourly/daily/weekly และตรวจ missing value
3. plot ข้อมูลเพื่อดู trend, seasonality, noise และ outlier
4. ทำ baseline model ก่อน เช่น naive, moving average, ARIMA/ETS หรือ Prophet
5. สร้าง multi-temporal features ถ้าข้อมูลมีหลาย rhythm
6. validate ด้วย chronological split หรือ walk-forward validation เท่านั้น
7. เลือก MAE/RMSE/MAPE ให้ตรงกับ business cost
8. ถ้าต้องการคำถาม Why ให้ใช้ causality เช่น VL-Granger/VL-TE ไม่ใช่แค่ feature importance
9. ถ้าต้องการดูโครงสร้าง ใช้ decomposition เช่น LGTD
10. ถ้าต้องการดูใครนำใครในหลาย entity ใช้ mFLICA หรือ following network

ประโยคสรุปสำหรับตอบสอบ

คำตอบสั้นแต่ครบ: Time Series Analysis คือการวิเคราะห์ข้อมูลตามเวลาเพื่อเข้าใจ temporal structure โดยสไลด์นี้แบ่ง ecosystem เป็น 4 มุม ได้แก่ prediction เพื่อทำนายอนาคต, causality เพื่อหาเหตุผลเชิง predictive precedence, structure เพื่อแยกองค์ประกอบของสัญญาณด้วย decomposition และ coordination เพื่อหา leader/follower ในระบบหลาย entity จุดสำคัญคือห้าม random split, ต้องเลือก metric ตามต้นทุนธุรกิจ, ใช้ multi-temporal features เมื่อข้อมูลมีหลาย rhythm และใช้ VL-Granger/VL-TE, mFLICA, LGTD ตามประเภทคำถาม

ตัวอย่างโปรเจกต์ Smart Factory แบบครบวงจร

ขั้นตอน	ทำอะไร	เครื่องมือที่เหมาะสม	Output
1. Data collection	เก็บ power load, temperature, production schedule, machine status	Data pipeline / sensor logging	time-indexed dataset

2. EDA	ดู trend, seasonality, noise, missing, outlier	plot, decomposition เบื้องต้น	เข้าใจโครงสร้างข้อมูล
3. Decomposition	แยก trend/repeating/residual	LGTD	clean components + anomaly residual
4. Forecasting	ทำนาย load/demand	ARIMA/Prophet/Multi-temporal/Deep model	next-hour load prediction
5. Validation	walk-forward evaluation	MAE, RMSE, MAPE	metric ที่เชื่อถือได้
6. Causality	หา sensor/machine ที่น่ากิน	VL-Granger หรือ VL-TE	causal graph / influence score
7. Coordination	หา factory/machine leader-follower	mFLICA	leaders/factions
8. Deployment	dashboard และ alert	API + dashboard	decision support

สิ่งที่ต้องระวังที่สุด

ความเข้าใจผิด	ที่ต้อง
Forecasting แม่น = เข้าใจเหตุผล	ไม่เสมอ ต้องใช้ causality ถ้าต้องการคำตอบ Why
Correlation = Causation	Correlation เป็นแค่ความสัมพันธ์ อาจมี confounder
Random split ใช้ได้กับทุกปัญหา	Time Series ต้อง split ตามเวลา
Deep learning ดีที่สุดเสมอ	ขึ้นกับข้อมูล baseline ง่าย ๆ อาจพอและอธิบายง่ายกว่า
Seasonality ต้อง fixed	โลกจริงอาจ drift, overlap, disappear หรือ intermittent
Leader คือคนอยู่หน้าสุด	Leader คือ entity ที่ pattern ถูกผู้อื่นตาม ไม่จำเป็นต้องอยู่หน้าเชิงตำแหน่ง

สรุปสุดท้าย: หยุดถามคำว่า “จะทำนายอย่างไร” แล้วเริ่มถามว่า “ความสัมพันธ์ที่ซ่อนอยู่ในเวลา คืออะไร” เพราะคำตอบที่ดีใน Time Series อาจไม่ใช่แค่ค่าพยากรณ์ แต่คือ insight ที่ช่วยให้ตัดสินใจและปรับระบบได้จริง

ภาคผนวก: สูตรและคำศัพท์ที่ควรจำ

คำศัพท์/สูตร	ความหมายแบบสั้น
$Y(t) = f(X_{2d}, X_{wk}, X_{mo})$	สูตร multi-temporal regression ใช้ feature หลาย time windows เพื่อทำนาย target
MAE	ค่า error absolute เฉลี่ย อธิบายง่าย
RMSE	ลงโทษ error ใหญ่หนัก เหมาะเมื่อ miss ใหญ่แพง
MAPE	error เป็นเปอร์เซ็นต์ เหมาะเปรียบเทียบหลาย scale แต่ระวัง actual ใกล้ศูนย์

DTW	Dynamic Time Warping ใช้ align time series ที่ยืดหดตามเวลา
BICDiffRatio	ตัววัด strength ของ VL-Granger โดยคำนึง model fit และ complexity
Transfer Entropy	วัด directed information flow จาก X ไป Y
mFLICA	framework หา leader/follower/faction จาก coordinated activities
LGTD	Local-Global Trend Decomposition แบบ season-length-free