

Chapter 10

Time Series Analysis

เอกสารสรุปละเอียดจากสไลด์: อ่านสอบ เข้าใจภาพรวม และต่อยอดทำ Hackathon

เป้าหมายของเอกสาร

เข้าใจ Time Series จาก 3 มุมมองหลัก: Time-domain, Frequency-domain และ Attention-based models

พร้อมตารางเลือกวิธีใช้งานจริง เช่น ARIMA, CNN, Fourier/FFT, Wavelet, Transformer และ Informer

สิ่งที่จะได้จากเอกสารนี้	รายละเอียด
ภาพรวม	Time Series Analysis คืออะไร ใช้ทำอะไร และ pattern สำคัญมีอะไรบ้าง
อ่านสอบ	แยกหัวข้อ แนวคิด ใช้ทำอะไร ต้องจำอะไร จุดที่มักออกสอบ
Hackathon	ตารางเลือกโมเดลตามลักษณะข้อมูล และ pipeline ที่เอาไปทำ prototype ได้
Machine Learning	เชื่อมโยง feature engineering, model selection, evaluation metrics และ visualization

อ้างอิงหลัก: Chapter 10: Time Series Analysis, CSS431: Machine Learning, Prachya Boonkwan (Arm), SIIT, Thammasat University.

สารบัญแบบเร็ว

ลำดับ	หัวข้อ	อ่านเพื่ออะไร
1	Introduction	รู้จัก time series, stationary, trend, seasonality, cycle
2	Time-Domain Methods	เข้าใจการมองข้อมูลตามเวลา
3	ARIMA Model	เข้าใจ p,d,q และการ forecast แบบ classical
4	Incomplete Time Series	รับมือ missing values ด้วย interpolation
5	Evaluation Metrics	เลือก MAE/RMSE/MAPE/Bias ให้เหมาะสม
6	Convolutional Analysis and CNNs	ใช้ kernel/CNN จับ local pattern
7	Frequency-Domain Methods	มองข้อมูลเป็นคลื่นและความถี่
8	Spectral Density + Fourier/FFT	หา frequency/seasonality ที่เด่น
9	Spectrogram	แปลง time series เป็นภาพ time-frequency
10	Wavelet/FWT + Scalogram	วิเคราะห์ signal ที่ noisy/non-stationary
11	Transformer + Attention	จับความสัมพันธ์ระยะไกลใน sequence
12	Informer	Transformer สำหรับ long sequence time-series forecasting
13	Model Selection Tables	ตารางเลือกโมเดลสำหรับโจทย์จริงและ Hackathon
14	Cheat Sheet	อ่านเร็วก่อนสอบ

0. ภาพรวมใหญ่ของ Time Series Analysis

Time Series คือข้อมูลที่ถูกเก็บตามลำดับเวลาในช่วงเวลาที่ห่างเท่ากัน เช่น ราคาหุ้นรายวัน ยอดขายรายเดือน สัญญาณเสียง สัญญาณ EEG/ECG อุณหภูมิ sensor หรือปริมาณวัตถุดิบที่ใช้ในโรงงาน

Time Series Analysis คือการวิเคราะห์ข้อมูลเหล่านี้เพื่อเข้าใจรูปแบบตามเวลา เช่น แนวโน้ม รอบซ้ำ ความผิดปกติ และใช้ทำนายค่าที่จะเกิดขึ้นในอนาคต

ง่ายมาก

ข้อมูลทั่วไปถามว่า “ค่าแต่ละแถวคืออะไร” แต่ Time Series ถามเพิ่มว่า “ค่าก่อนหน้าเกี่ยวกับค่าถัดไปอย่างไร” เพราะลำดับเวลามีความหมาย

สิ่งที่ Time Series ใช้ทำ	ตัวอย่างงานจริง	แนวคิดที่เกี่ยวข้อง
Forecasting	ทำนาย demand วัตถุดิบ / ยอดขาย / traffic / stock price	ARIMA, Transformer, Informer
Anomaly Detection	ตรวจจับ sensor เครื่องจักรผิดปกติ / ใช้วัตถุดิบเกิน theory	CNN, FFT, Wavelet, Autoencoder
Pattern Recognition	แยกเสียงพูด / classifying ECG / EEG	Spectrogram/Scalogram + CNN
Trend Analysis	ดูแนวโน้มยอดขายหรือราคา	Moving average, regression, ARIMA
Seasonality Detection	ดูรอบรายวัน รายสัปดาห์ รายเดือน	Autocorrelation, Fourier, Spectral density
Event Effect	ผลจากวันหยุด โปรโมชัน shutdown	Feature engineering, attention, CNN

1. Introduction

1.1 Time Series คืออะไร

Time series คือ sequence ของ data points ที่ถูกอ่านตามช่วงเวลาเท่า ๆ กัน ความสำคัญอยู่ที่ “ลำดับ” เพราะค่าที่อยู่ใกล้กันในเวลามักสัมพันธ์กันมากกว่าค่าที่อยู่ไกลกัน

ตัวอย่างข้อมูล	Time step	ค่าที่วัด	สิ่งที่อยากรู้
ราคาหุ้น	รายวัน	ราคาเปิด/ปิด/volume	พรุ่งนี้ราคาจะขึ้นไหม
ยอดขายสินค้า	รายวัน/รายเดือน	จำนวนขาย รายได้	เดือนหน้าต้อง stock เท่าไร
Sensor โรงงาน	ทุกวินาที/นาที่	temperature, vibration, current	เครื่องจักรเริ่มผิดปกติไหม
Audio signal	หลายพัน sample/วินาที	amplitude	เป็นเสียงคำอะไรบ้าง

EEG/ECG	ตาม sampling rate	สัญญาณไฟฟ้าชีวภาพ	สภาวะปกติหรือผิดปกติ
---------	-------------------	-------------------	----------------------

1.2 Stationary vs Non-Stationary

ประเภท	ความหมาย	ตัวอย่าง	ผลต่อการเลือกโมเดล
Stationary	ค่าเฉลี่ย ความแปรปรวน และความสัมพันธ์ตาม lag ไม่เปลี่ยนแปลงตามเวลา	noise แกว่งรอบค่าเดิม / signal รอบซ้ำคงที่	เหมาะกับ Fourier, spectral density, ARIMA หลัง differencing
Non-Stationary	ค่าเฉลี่ยหรือ variance เปลี่ยนตามเวลา เช่น มี trend หรือช่วงผันผวนเปลี่ยน	ราคาหุ้นที่ขึ้นเรื่อย ๆ / EEG / speech	เหมาะกับ wavelet, scalogram, Transformer หรือ preprocessing ก่อน

ภาพจำ

Stationary = คลื่นนิ่งสั่นคงที่, Non-stationary = คลื่นเปลี่ยนอารมณ์ไปตามเวลา

1.3 Patterns in Time Series

Pattern	แปลว่า	ตัวอย่าง	ถามตัวเองว่า
Trend	ทิศทางหลักระยะยาว	ยอดขายโตขึ้นทุกเดือน	กราฟโดยรวมขึ้นหรือลงไหม
Seasonality	รูปแบบซ้ำเป็นรอบที่คาดเดาได้	ยอดขายสูงทุกวันศุกร์ / ไฟสูงหน้าร้อน	มีรอบซ้ำรายวัน/สัปดาห์/เดือน ไหม
Holiday Effect	รูปแบบผิดปกติจาก calendar event	ยอดขายพุ่งวัน 11.11 หรือปีใหม่	มี event พิเศษที่ทำให้ข้อมูลกระโดดไหม
Cycle	วัฏจักรระยะยาว ไม่ได้สม่ำเสมอเท่า seasonality	เศรษฐกิจขึ้นลงหลายปี	มีคลื่นใหญ่ระยะยาวไหม

1.4 Assumptions จากสไลด์

กลุ่มวิธี	Assumption หลัก	แปลแบบง่าย
Time domain	Stochastic process + temporal structures	อดีตใกล้ ๆ มักเกี่ยวกับปัจจุบัน และข้อมูลประกอบด้วย trend/season/holiday/cycle
Frequency domain	Combination of continuous waves	ข้อมูลคือคลื่นหลายความถี่ผสมกัน
Wavelet domain	Combination of wavelets	ข้อมูลคือคลื่นขึ้นเล็ก ๆ หลาย scale ผสมกัน
Sequence-to-sequence	Transformer-based models	ข้อมูลเป็น sequence ที่ตำแหน่งต่าง ๆ สนใจกันได้ผ่าน attention

2. Time-Domain Methods

Time-domain methods วิเคราะห์ข้อมูลในมุมมองของเวลาโดยตรง เช่น ใช้ค่าก่อนหน้า ค่าความต่างก่อนหน้า error ก่อนหน้า หรือ pattern ใน window สั้น ๆ เพื่อทำนายค่าปัจจุบัน/อนาคต

แก่นของ Time-domain

อนาคต = ฟังก์ชันของอดีต เช่น ยอดขายพรุ่งนี้อาจขึ้นกับยอดขายเมื่อวาน วันเดียวกันของสัปดาห์ก่อน และผลจากโปรโมชั่น

วิธีในกลุ่ม Time-domain	มองอะไร	ใช้ทำอะไร	ข้อควรระวัง
ARIMA	ค่าอดีต + differencing + error	forecasting แบบคลาสสิก	ไม่เด่นกับ nonlinear pattern ที่ซับซ้อน
Convolution/CNN	local pattern ใน window	classification, anomaly, forecast จาก feature สั้น ๆ	จับ long dependency ได้จำกัดถ้า network/window ไม่พอ
Rolling features	ค่าเฉลี่ย/variance ในช่วงล่าสุด	feature engineering สำหรับ ML	ต้องระวัง data leakage

3. ARIMA Model

3.1 แนวคิดหลัก

ARIMA ย่อมาจาก Auto-Regressive Integrated Moving Average เป็นโมเดล forecasting แบบ classical ที่ใช้ความสัมพันธ์เชิงเส้นของค่าก่อนหน้า ความต่างตาม season/differencing และ error ก่อนหน้า

ส่วนของ ARIMA	ความหมาย	จำแบบสั้น	ตัวอย่าง
AR: Auto-Regressive	ใช้ค่าหรือความต่างก่อนหน้าเป็น input	อดีตทำนายปัจจุบัน	ยอดขายวันนี้ขึ้นกับยอดขายเมื่อวาน
I: Integrated	ทำ differencing เพื่อลด trend/season และทำให้ข้อมูลนิ่งขึ้น	เอาค่าไปลบค่าก่อนหน้า/ค่าข้าม season	$x_t - x_{t-d}$
MA: Moving Average	ใช้ error ก่อนหน้าช่วยปรับค่าทำนาย	เรียนจากความผิดพลาดเดิม	ถ้า model เคยทำนายต่ำไป ก็ปรับขึ้น

3.2 ARIMA(p,d,q)

Parameter	หมายถึง	ในสไลด์ใช้แนวคิด	ถามสอบบ่อย
p	จำนวน previous differences ที่ใช้	No. cross-seasonal differences	p สูงขึ้น = ใช้อดีตหลายจุดขึ้น
d	season duration / differencing lag	Season duration d timesteps	d ช่วยสร้างความต่างข้าม season
q	จำนวน previous errors ที่ใช้	No. previous errors	q ช่วยปรับจาก error ในอดีต

3.3 ตัวอย่างตามสไลด์แบบเข้าใจง่าย

สมมติ season length d = 3 และมีข้อมูล: Day1=10, Day2=15, Day3=20, Day4=25, Day5=28, Day6=38

t	x_t	x_{t-d}	difference x' = x_t - x_{t-d}	ความหมาย
1	10	-	-	ยังไม่มีค่าข้าม season
2	15	-	-	ยังไม่มีค่าข้าม season
3	20	-	-	ยังไม่มีค่าข้าม season
4	25	10	15	Day4 โตจาก Day1 เท่าไร
5	28	15	13	Day5 โตจาก Day2 เท่าไร
6	38	20	18	Day6 โตจาก Day3 เท่าไร

วิธีคิด ARIMA

1) สร้าง difference ก่อน 2) ใช้ previous differences ทำนาย difference ถัดไป 3) ใช้ previous errors ปรับค่าทำนาย 4) แปลง difference กลับเป็นค่าจริง

3.4 ใช้ ARIMA เมื่อไหร่

เหมาะ	ไม่เหมาะสมมาก	Hackathon Tip
ข้อมูลตัวเลขต่อเนื่อง มี season/trend ชัด เช่น demand, sales, price	ข้อมูลซับซ้อน nonlinear, มีหลาย feature และ dependency ยาวมาก	ใช้ ARIMA เป็น baseline ก่อนเสมอ เพราะอธิบายง่ายและเทียบกับ deep learning ได้ดี

3.5 จุดที่มักออกสอบ

- ARIMA(p,d,q) แต่ละตัวหมายถึงอะไร
- ทำไมต้อง differencing
- AR ต่างจาก MA อย่างไร
- ARIMA เหมาะกับ stationary หรือ non-stationary ที่ถูกทำให้ stationary แล้ว
- ข้อจำกัดของ ARIMA คือมักเป็น linear และต้องเลือก parameter ให้เหมาะ

4. Incomplete Time Series

Incomplete Time Series คือข้อมูลที่มีค่าหาย เช่น sensor ไม่ส่งค่า, server ล่ม, data logging ขาดช่วง
หรือไม่มีข้อมูลในวันหยุด ก่อน train model มักต้องเติมค่าหายหรือจัดการ missing values

วิธี Interpolation	แนวคิด	เหมาะกับ	ข้อควรระวัง
Linear interpolation	ลากเส้นตรงระหว่างค่าก่อนหน้าและถัดไป	ข้อมูลเปลี่ยนไม่ซับซ้อน	อาจไม่ smooth
Newton interpolation	ใช้ polynomial จาก divided differences	ต้องการประมาณค่าทางคณิตศาสตร์	degree สูงอาจแกว่ง
Cubic spline	ใช้เส้นโค้ง cubic ต่อกันอย่าง smooth	ข้อมูลเปลี่ยนนุ่ม ๆ เช่น temperature	ถ้า missing ยาวมากอาจหลุดตา
Chebyshev interpolation	เหมาะกับ pattern sinusoidal/seasonality	ข้อมูลเป็นรอบคลื่น	ต้องเข้าใจช่วงและรูปคลื่น
Radial Basis Function	ประมาณค่าจากอิทธิพลรอบจุดข้อมูล	nonlinear หรือกระจายตัวซับซ้อน	ต้องเลือก function/parameter

Interpolation vs Forecasting

Interpolation = เติมค่าที่หาย “ระหว่างช่วงที่รู้แล้ว” / Forecasting = ทำนาย “อนาคตที่ยังไม่รู้”

4.1 Pipeline จัดการ missing values

- 1. ตรวจสอบว่า missing อยู่ช่วงไหน และหายต่อเนื่องยาวแค่ไหน
- 2. แยก missing แบบสุ่มกับ missing เพราะระบบ/event เช่น shutdown
- 3. ถ้าหายสั้น ใช้ linear/cubic spline ได้
- 4. ถ้าข้อมูลเป็น season หรือคลื่น ใช้ Chebyshev / Fourier / Wavelet feature ช่วยได้
- 5. สร้าง flag เพิ่มว่า row นี้เคย missing เพื่อให้ model รู้ว่าค่านี้ถูกเติมมา
- 6. อย่าเติมค่าจากอนาคตในชุด test จนเกิด data leakage

5. Evaluation Metrics

การ forecast ต้องวัดผลด้วย metric ที่สะท้อนโจทย์จริง ไม่ใช่ดูกราฟอย่างเดียว ในสไลด์ให้ MAE, RMSE, MAPE และ Forecast Bias

Metric	สูตรเชิงความหมาย	แปลว่า	ใช้เมื่อ	ข้อควรระวัง
MAE	$\text{average}(y - \hat{y})$	ผิดพลาดกี่หน่วย	อยากอธิบายง่าย เช่น ผิดเฉลี่ย 12 ชิ้น	ไม่ลงโทษ error ใหญ่แรงเท่า RMSE
RMSE	$\sqrt{\text{mean}((y - \hat{y})^2)}$	ผิดพลาดแบบเน้น error ใหญ่	งานที่ error ใหญ่เสียหายมาก	sensitive ต่อ outlier
MAPE	$\text{average}(y - \hat{y} /y)$	ผิดพลาดกี่เปอร์เซ็นต์	เทียบหลายสินค้า/หลาย scale	ใช้ยากเมื่อ y จริงใกล้ 0
Forecast Bias	$\text{average}(y - \hat{y})$ หรือ prediction - actual ตามนิยามที่ใช้	model ชอบทำนายสูงหรือต่ำไปไหม	งาน inventory/stock สำคัญมาก	ค่า + และ - อาจหักล้างกัน

Hackathon Tip

รายงานอย่างน้อย 3 อย่าง: MAE เพื่ออ่านง่าย, RMSE เพื่อดู error ใหญ่, Bias เพื่อบอกว่า model over-forecast หรือ under-forecast

โจทย์	Metric ที่ควรเน้น	เหตุผล
Demand วัตถุดิบ	MAE + Bias	รู้ว่าต้องเผื่อของกี่หน่วย และ model ชอบทำนายขาด/เกินไหม
เครื่องจักร critical	RMSE หรือ cost-weighted error	error ใหญ่มีผลเสียมาก
เปรียบเทียบหลายสินค้า	MAPE หรือ sMAPE	ต้อง normalize scale
Anomaly Detection	Precision/Recall/F1 เพิ่มเติม	forecast metric อย่างเดียวไม่พอสำหรับ alarm

6. Convolutional Analysis and CNNs

6.1 Convolution คืออะไร

Convolution คือการเอา kernel/filter ไปเลื่อนทับกับ input เพื่อหาว่าช่วงไหนของข้อมูลคล้าย pattern ที่ kernel ต้องการ ถ้าคล้ายกันค่าจะถูก amplify หรือเด่นขึ้น

คำ	ความหมาย	ตัวอย่างใน Time Series
Input signal	ข้อมูล time series ทั้งเส้น	ค่า vibration 1 ชั่วโมง
Kernel / Filter	pattern สั้น ๆ ที่ใช้ค้นหา	รูปคลื่น spike, รูปคลื่นขึ้นแล้วลง
Feature map	ผลลัพธ์หลังเลื่อน kernel	ตำแหน่งไหนมี pattern นั้นมาก
Pooling	เลือก feature เด่น/ย่อขนาด	เก็บ spike ที่เด่นที่สุดในช่วงนั้น
ReLU	nonlinear activation	ตัดค่าติดลบ/เน้นสัญญาณบวก

6.2 Convolution vs Cross-Correlation

ในคณิตศาสตร์ convolution จะ flip kernel ก่อนคูณรวม ส่วน cross-correlation ไม่ flip kernel และมักใช้วัด similarity ของ wave ใน deep learning หลายครั้งเรียก operation นี้รวม ๆ ว่า convolution เพื่อให้ง่าย

6.3 CNN สำหรับ Time Series

CNN เรียน kernel จากข้อมูลเอง ไม่ต้องกำหนด pattern เอง โครงสร้างที่สไลด์แสดงคือ Conv1D หลาย kernel -> Max Pooling -> ReLU -> Flatten -> MLP สำหรับทำนายหรือ classify

Layer	ทำอะไร	ภาพจำ
Conv1D	เลื่อน kernel ตามแกนเวลาเพื่อหา local pattern	เหมือนใช้แม่แบบสั้น ๆ หา pattern ในกราฟยาว
Max Pooling	เลือกค่าที่เด่นที่สุด ลดขนาด feature map	เก็บเฉพาะตำแหน่งที่ match แรง
ReLU	เพิ่ม nonlinear ability	ทำให้ model จับ pattern ซับซ้อนขึ้น
Flatten	แปลง feature map เป็น vector	เตรียมส่งเข้า MLP
MLP/Output	ทำนาย class หรือค่าต่อเนื่อง	เช่น anomaly/normal หรือ demand วันถัดไป

6.4 ใช้ CNN เมื่อไหร่

เจอข้อมูลแบบนี้	ใช้ CNN อย่างไร	ตัวอย่าง Hackathon
Sensor มี pattern สั้น ๆ	Conv1D บน raw time series	ตรวจจับ vibration pattern ที่คล้าย failure
Audio/Speech	แปลงเป็น spectrogram แล้วใช้ Conv2D	classify เสียงเครื่องจักร/เสียงพูด
EEG/ECG/Heart sound	แปลงเป็น scalogram/spectrogram แล้วใช้ Conv2D	แยก normal/abnormal
ยอดขายมี local spike	Conv1D + time features	จับ promotion spike หรือ holiday effect

6.5 จุดที่มักออกสอบ

- Kernel คือ pattern filter ใช้ค้นหาความคล้ายในข้อมูล
- Convolution ช่วย extract local features
- Conv1D ใช้กับ time series ดิบ ส่วน Conv2D ใช้กับภาพอย่าง spectrogram/scalogram
- Max pooling ช่วยเลือก feature เด่นและลดขนาดข้อมูล
- CNN เก่ง local pattern แต่ long-range dependency ต้องออกแบบ receptive field ให้พอ หรือใช้ Transformer

7. Frequency-Domain Methods

Frequency-domain methods เปลี่ยนมุมมองจากกราฟตามเวลาเป็นการดูว่า signal ประกอบด้วยความถี่อะไรบ้าง
เหมาะมากกับข้อมูลที่มีรอบซ้ำ คลื่น เสียง vibration หรือ seasonality

Time Domain	Frequency Domain
ถามว่า “ค่าข้อมูลเปลี่ยนตามเวลาอย่างไร”	ถามว่า “ข้อมูลประกอบด้วยความถี่อะไรบ้าง”
เหมาะกับ trend, lag, recent values	เหมาะกับ seasonality, periodicity, vibration, audio
ตัวอย่าง: ARIMA, CNN 1D	ตัวอย่าง: Fourier, FFT, spectral density, spectrogram

ภาพจำ

ถ้า time-domain คือดูคลื่นจากด้านข้าง frequency-domain คือแยกคลื่นออกเป็นโน้ตดนตรีหลายตัวว่ามีตัวไหนดังบ้าง

8. Spectral Density Analysis

Spectral Density คือการอธิบาย time series ด้วยพลังงานหรือ power ที่กระจายตาม frequency components โดยสมมติว่า time series เป็นส่วนผสมของ periodic sinusoid waves

สิ่งที่เห็นใน spectrum	ความหมาย	ตัวอย่าง
Peak สูงที่ frequency หนึ่ง	frequency นั้นเด่น มี pattern ชัด	ยอดขายมีรอบรายสัปดาห์
หลาย peak	มีหลายรอบซ้ำผสมกัน	รายวัน + รายสัปดาห์ + รายเดือน
ไม่มี peak ชัด	อาจเป็น noise หรือ pattern ไม่คงที่	sensor noisy มาก
peak เปลี่ยนตามเวลา	Fourier ธรรมดาอาจไม่พอ ต้องใช้ spectrogram/wavelet	speech หรือ EEG

8.1 ใช้ทำอะไร

- หา seasonality hidden ในข้อมูล เช่น รอบ 7 วัน หรือ 24 ชั่วโมง
- ตรวจจับความถี่ผิดปกติของเครื่องจักร
- สร้าง feature จาก frequency เพื่อป้อนเข้า ML model
- ตรวจสอบว่าข้อมูลเหมาะกับ Fourier/FFT หรือควรใช้ Wavelet แทน

9. Fourier Transform / FFT

9.1 Fourier Transform

Fourier Transform คิดว่า time series $x(t)$ align กับ wave ความถี่ต่าง ๆ ดีแค่ไหน ถ้า align ดี แสดงว่าความถี่นั้นเป็นองค์ประกอบสำคัญของ signal

คำ	แปลแบบง่าย
Wave frequency	จำนวนรอบการสั่นต่อเวลา
Amplitude	ความแรงของคลื่น
Phase	ตำแหน่งเริ่มต้นของคลื่น
Spectrum	ภาพรวมว่ามี frequency อะไรและแรงแค่ไหน
Squared magnitude / power	ความแรงของ frequency นั้นใน signal

จุดแข็ง-จุดอ่อน

Fourier เก่งมากในการบอกว่า “มี frequency อะไรบ้าง” แต่ไม่เก่งในการบอกว่า “frequency นั้นเกิดเมื่อไหร่”

9.2 FFT

FFT หรือ Fast Fourier Transform คือ algorithm ที่คำนวณ Fourier Transform ได้เร็ว โดยสไลด์ระบุ complexity เป็น $O(n \log n)$ ซึ่งเหมาะกับ signal ยาวหรือข้อมูลที่ต้องประมวลผลเร็ว

ใช้ FFT ในงานไหน	ทำอะไร
Audio	หา frequency pattern ของเสียง
Vibration monitoring	หา frequency ผิดปกติของ motor/bearing
Demand seasonality	หารอบซ้ำรายวัน/สัปดาห์/เดือน
Feature engineering	นำ top frequency peaks ไปเป็น feature ให้ ML
Data visualization	แสดง spectrum เพื่ออธิบาย signal

9.3 จุดที่มักออกสอบ

- Fourier Transform แปลงข้อมูลจาก time domain ไป frequency domain
- FFT เป็นวิธีคำนวณ Fourier ที่เร็วขึ้น มี $O(n \log n)$
- Fourier เหมาะกับ stationary signal มากกว่า non-stationary signal
- ถ้าต้องรู้ว่า frequency เกิดช่วงไหน ให้ใช้ spectrogram หรือ wavelet

10. Spectrogram

Spectrogram คือการแบ่ง time series เป็น window ย่อย ๆ แล้วทำ FFT แต่ละ window จากนั้นแสดงเป็น heatmap แกนหนึ่งเป็นเวลา อีกแกนเป็น frequency และสีคือ power/amplitude

Fourier ธรรมดา	Spectrogram
มองทั้ง signal เป็นก้อนเดียว	แบ่ง signal เป็นช่วงเวลาเล็ก ๆ
บอก frequency โดยรวม	บอกว่าเวลาไหนมี frequency อะไร
เหมาะกับ stationary signal	เหมาะกับ signal ที่เปลี่ยนแปลงตามเวลาในระดับหนึ่ง
output เป็น spectrum	output เป็นภาพ heatmap time-frequency

10.1 Spectrogram + CNN

ในสไลด์ยกตัวอย่าง speech recognition ว่า spectrogram ใช้เป็น input picture สำหรับ CNN-based models โดย local features คือการเปลี่ยนแปลงในช่วง frequency เฉพาะ และมักใช้ Conv2D

ขั้นตอน	ทำอะไร	เหตุผล
Raw audio/signal	เก็บ amplitude ตามเวลา	ข้อมูลดิบยังดู pattern ยาก
Windowing	แบ่ง signal เป็นช่วง ๆ	เพื่อรู้ frequency ตามเวลา
FFT per window	แปลงแต่ละช่วงเป็น frequency	ได้ spectrum ของแต่ละเวลา
Spectrogram image	รวมเป็น heatmap	ทำให้ใช้ computer vision ได้
Conv2D/CNN	เรียน local pattern บนภาพ	จับ formant/เสียง/ความถี่ผิดปกติ

Hackathon Tip

ถ้าโจทย์มีเสียงหรือ vibration แล้วต้อง classify ให้ลองทำ spectrogram + CNN เพราะ demo เห็นภาพง่ายมาก และอธิบายกับกรรมการได้ชัด

11. Wavelet Analysis / FWT

11.1 Wavelet Transform คืออะไร

Wavelet Transform คล้าย Fourier แต่ใช้ wavelet ซึ่งเป็นคลื่นสั้น ๆ ที่เลื่อนตำแหน่งและเปลี่ยน scale/frequency ได้ ทำให้รู้ทั้งความถี่และตำแหน่งเวลา เหมาะกับ signal ที่เปลี่ยนแปลงตลอดเวลา

Fourier	Wavelet
ใช้ sine/cosine wave ยาวทั้ง signal	ใช้คลื่นสั้นเล็ก ๆ ที่เลื่อนไปตามเวลา
บอก frequency ดี แต่ตำแหน่งเวลาไม่ละเอียด	บอกทั้ง frequency/scale และตำแหน่งเวลา
เหมาะกับ stationary	เหมาะกับ non-stationary และ noisy
ตัวอย่าง: seasonality คงที่	ตัวอย่าง: EEG, speech, heart sound, transient fault

11.2 FWT: Fast Wavelet Transform

FWT ทำงานแบบหลาย resolution โดยใช้ wavelet filter g เพื่อดึงรายละเอียด และ low-pass filter h เพื่อลด noise/ทำข้อมูลให้หายาบลงเรื่อย ๆ สไลด์ระบุ complexity $O(n \log n)$

ส่วนประกอบ	หน้าที่	ภาพจำ
------------	---------	-------

Wavelet filter g	ดึง detail หรือการเปลี่ยนแปลงเฉพาะช่วง	หา edge/spike/peak
Low-pass filter h	กรองความถี่สูง/noise และเก็บภาพรวม	ทำให้ signal smooth
Resolution level L	จำนวนระดับการแยก scale	ยิ่งหลายระดับ ยิ่งเห็นหลาย scale
Coefficients	ค่าที่บอกว่า wavelet match signal แค่ไหน	peak = มี pattern นั้น

11.3 ใช้ Wavelet เมื่อไหร่

ข้อมูล	เหตุผลที่ Wavelet เหมาะ	ตัวอย่างโมเดลต่อยอด
EEG/brain wave	signal noisy และเปลี่ยนตามเวลา	Scalogram + CNN/LSTM
ECG/heart sound	มี peak สำคัญเฉพาะช่วง	Wavelet features + classifier
Speech	frequency เปลี่ยนเร็วตามเสียง	Scalogram/Spectrogram + CNN
Fault signal	anomaly เกิดเป็นช่วงสั้น ๆ	Wavelet anomaly detection
Image compression	แยกภาพหลาย resolution	Haar wavelet / JPEG-like idea

12. Scalogram

Scalogram คือ heatmap ที่ได้จาก wavelet transform คล้าย spectrogram แต่ใช้ wavelet/FWT แทน FFT จึงเหมาะกับ signal ที่ non-stationary และ noisy เช่น speech, EEG และ brain waves

สิ่งที่เห็นใน Scalogram	ความหมาย
Peak	มี wavelet pattern อยู่ ณ ตำแหน่ง/scale นั้น
Horizontal ridge	frequency คงที่ต่อเนื่องตามเวลา
Vertical ridge	มีลำดับเหตุการณ์/constant frequency ในช่วงเวลา
Separate ridges	มีหลาย tune หรือหลาย pattern ผสมกัน
สีเข้ม/สว่างตาม scale	บอกพลังงานหรือความแรงของ pattern

Spectrogram	Scalogram
สร้างจาก FFT บน window	สร้างจาก Wavelet/FWT
ดีสำหรับ stationary หรือ signal ที่ความถี่ค่อนข้างคงที่	ดีสำหรับ non-stationary/noisy signal
resolution ขึ้นกับ window size	เห็นหลาย scale ตาม wavelet
นิยมกับ audio/speech	นิยมกับ EEG/ECG/brain wave/fault transient
ใช้เป็นภาพเข้า Conv2D ได้	ใช้เป็นภาพเข้า Conv2D ได้

Spectrogram = FFT เป็นรูปภาพ / Scalogram = Wavelet เป็นรูปภาพ

13. Transformer for Time Series

Transformer เดิมใช้กับ sequence-to-sequence เช่น translation แต่ time series ก็เป็น sequence จึงประยุกต์ใช้กับ forecasting, anomaly detection และ multivariate time series ได้

ทำไม Transformer เหมาะกับ Time Series	ตัวอย่าง
จับ long-range dependency ได้	ยอดขายวันนี้อาจเกี่ยวกับวันเดียวกันเมื่อหลายสัปดาห์ก่อน
เรียนความสัมพันธ์หลายตำแหน่งพร้อมกัน	sensor หลายช่วงเวลาส่งผลต่อ anomaly ตอนนี้
รองรับ multivariate features	ใช้ temperature, stock, order, calendar พร้อมกัน
ทำ sequence-to-sequence forecasting ได้	input 96 ชั่วโมง -> output 24 ชั่วโมงข้างหน้า

ข้อดี	ข้อเสีย
จับความสัมพันธ์ระยะไกลได้ดีกว่า CNN/ARIMA หลายกรณี	ใช้ data, memory และเวลา train เยอะ
attention ช่วยตีความได้ว่าจุดไหนสำคัญ	vanilla attention มี $O(L^2)$ เมื่อ sequence ยาว
เหมาะกับ multivariate และ long-term forecasting	ต้องจัดการ positional/time embedding ให้ดี

14. Attention, Self-Attention, Cross-Attention, Multihead Attention

14.1 Scaled Dot-Product Attention

Attention ทำหน้าที่เหมือน search engine: Query ไปเทียบกับ Key ถ้า key ไหนคล้าย query มาก value ของ key นั้นจะได้ weight สูง และถูกนำมารวมเป็นผลลัพธ์

คำ	ความหมาย	ตัวอย่าง Time Series
Query	สิ่งที่กำลังถาม/ตำแหน่งที่กำลังทำนาย	เวลาปัจจุบันหรืออนาคตที่ต้อง forecast
Key	สิ่งที่ใช้เทียบความเกี่ยวข้อง	ทุก timestep ในอดีต
Value	ข้อมูลที่จะถูกดึงมาใช้	feature หรือ hidden state ของแต่ละ timestep
Weight	คะแนนความสำคัญหลัง softmax	วันนี้ควรสนใจวันไหนในอดีตมากที่สุด
Result	weighted sum ของ values	context vector สำหรับทำนาย

14.2 Self-Attention

Self-Attention คือ attention ที่ query, key และ value มาจาก sequence เดียวกัน ใช้หาว่าแต่ละตำแหน่งใน sequence ควรสนใจตำแหน่งอื่น ๆ ใน sequence เดียวกันมากแค่ไหน

จำสั้น

Self-Attention = sequence สนใจตัวเอง

14.3 Cross-Attention

Cross-Attention คือ query มาจาก target sequence ส่วน key/value มาจาก source sequence เหมาะกับ encoder-decoder เช่น ใช้ถอดเป็น source และอนาคตที่ต้องทำนายเป็น target

จำสั้น

Cross-Attention = target ไปถาม source

14.4 Multihead Attention

Attention หัวเดียวอาจจับ relationship ได้แบบเดียว Multihead Attention ใช้หลาย head เพื่อจับหลาย pattern พร้อมกัน เช่น head หนึ่งจับรายวัน อีก head จับรายสัปดาห์ อีก head จับ holiday effect

Attention Head	อาจเรียนรู้อะไรใน Time Series
Head 1	trend ระยะสั้น
Head 2	seasonality รายวัน
Head 3	seasonality รายสัปดาห์
Head 4	holiday/promotion effect
Head 5	anomaly spike
Head 6	long-term dependency

14.5 จุดที่มักออกสอบ

- Attention ใช้ query, key, value และ softmax weight
- Self-attention ใช้ sequence เดียวกันเป็น query/key/value

- Cross-attention ใช้ target query ไปสนใจ source key/value
- Multihead attention ช่วยจับความสัมพันธ์หลายประเภทพร้อมกัน
- ข้อเสียของ vanilla attention คือ $O(L^2)$ เมื่อ sequence ยาว

15. Informer

Informer เป็น Transformer-like model สำหรับ Long Sequence Time-Series Forecasting (LSTF) ออกแบบมาแก้ปัญหา vanilla Transformer ที่ช้าและกิน memory เมื่อ sequence ยาว

ปัญหาของ Vanilla Transformer	ผลเสีย	Informer แก้ไขอย่างไร
Self-attention เป็น $O(L^2)$	sequence ยาวแล้ว memory/time ระเบิด	ProbSparse Self-Attention ลดเหลือประมาณ $O(L \log L)$
Stack หลาย layer ทำให้ memory bottleneck	input ยาวมากรับไม่ไหว	Self-Attention Distilling ลดขนาด feature map
ทำนาย output ยาวแบบ step-by-step ช้า	inference ช้าและ error สะสม	Generative-style Decoder ทำนายยาวใน forward เดียว

องค์ประกอบ Informer	หน้าที่	จำแนกง่าย
ProbSparse Self-Attention	เลือก attention สำคัญ ไม่คำนวณเต็มทุกคู่	สนใจเฉพาะจุดที่สำคัญจริง
Self-Attention Distilling	ใช้ Conv1D + activation + MaxPool เพื่อลดความยาว feature	กลั่นข้อมูลให้เหลือ feature เด่น
Generative Decoder	สร้าง output sequence ยาวในครั้งเดียว	ไม่ต้องทำนายทีละ step
Encoder replicas / stack	ช่วยรับ input ยาวหลาย scale	เพิ่ม robustness

15.1 ใช้ Informer เมื่อไหร่

- ต้อง forecast sequence ยาว เช่น 24, 96, 168 timestep ข้างหน้า
- มี multivariate features หลายตัว เช่น demand, stock, calendar, temperature, production plan
- Vanilla Transformer กิน memory/เวลาเกินไป
- ต้องการโมเดลที่จับ long-range dependency ได้มากกว่า ARIMA/CNN

16. ตารางเปรียบเทียบใหญ่: ARIMA vs CNN vs Fourier vs Wavelet vs Transformer

วิธี	มองข้อมูลแบบไหน	จุดเด่น	จุดอ่อน	เหมาะกับ
ARIMA	time-domain + linear lag/difference	อธิบายง่าย ใช้เป็น baseline ดี	ไม่เก่ง nonlinear/multivariate complex	sales, demand, price
CNN/Conv1D	local pattern ตามเวลา	จับ pattern สั้น ๆ ได้ดี เรียน kernel เอง	long dependency จำกัด	sensor, ECG, anomaly, short forecast
Fourier/FFT	frequency-domain	หา seasonality/frequency เด่นดีมาก	ไม่รู้ตำแหน่งเวลา event ดี	audio, vibration, stationary signal
Spectrogram + CNN	time-frequency image	แปลง signal เป็นภาพให้ CNN เรียนได้	ขึ้นกับ window size	speech, sound, vibration
Wavelet/FWT	time-frequency-scale	ดีต่อ noisy/non-stationary และ transient event	ซับซ้อนกว่า Fourier	EEG, ECG, fault detection
Scalogram + CNN	wavelet image	เห็น event + frequency + scale	ต้องเลือก wavelet/scale	brain wave, heart sound, non-stationary signal
Transformer	sequence relation	จับ dependency ระยะไกลและหลาย feature	แพง $O(L^2)$	long-term forecasting
Informer	efficient transformer	เหมาะกับ sequence ยาวมาก	implementation ซับซ้อน	LSTF, multivariate long forecast

17. ตารางเลือกโมเดลตามสถานการณ์จริง

สถานการณ์ที่เจอ	ลักษณะข้อมูล	วิธีที่แนะนำ	เหตุผล
ยอดขายมี season ชัด	linear + seasonality	ARIMA / SARIMA / baseline	ง่าย อธิบายได้
ข้อมูลมี missing values	มีช่องว่าง	Interpolation ก่อน	ต้องทำให้ timeline สมบูรณ์
sensor มี spike สั้น ๆ	local pattern	CNN/Conv1D	kernel จับรูปคลื่นเฉพาะช่วง
เสียงหรือ vibration	frequency สำคัญ	FFT/Spectrogram + CNN	frequency pattern ชัด
signal ค่อนข้าง stationary	frequency คงที่	Fourier/Spectral density	หา peak ความถี่ได้ดี
signal noisy/non-stationary	frequency เปลี่ยนตามเวลา	Wavelet/Scalogram	เห็นเวลาและ scale
ต้องทำนายยาวหลาย step	long dependency	Transformer/Informer	attention ดูอดีตไกล ๆ ได้
sequence ยาวมาก	memory issue	Informer	ลด complexity

ข้อมูลน้อยใน Hackathon	small dataset	ARIMA + feature engineering + tree model	ลด overfit
ข้อมูลเยอะ หลาย feature	multivariate	Transformer/Informer/CNN hybrid	เรียน pattern ซับซ้อนได้

18. ตารางสรุปตาม Conclusion ของสไลด์

สไลด์ท้ายบทเปรียบเทียบว่าแต่ละ model รองรับ trend, seasonality, holiday effects, cycle และเหมาะกับ signal type แบบไหน สรุปให้อ่านง่ายดังนี้

Model	Trend	Seasonality	Holiday Effects	Cycle	เหมาะกับ Signal Type
ARIMA	ได้ จาก linear regression	ได้ แต่จำกัดตาม season length	ไม่เด่น	ไม่เด่น	ข้อมูลเชิงตัวเลขที่ pattern ค่อนข้างเรียบ
Convolution/CNN	ได้ จาก kernel ที่เรียนรู้	ได้ แต่จำกัดตาม window size	ได้ ถ้ามี pattern ใน data	อาจไม่ดีถ้า cycle ยาวเกิน window	local pattern / sensor / image-like
Spectral Density	เห็นผ่าน frequency/power	ได้ดีใน frequency domain	อาจเห็นถ้าแปลงเป็น spectrogram/CNN	เห็นใน spectrogram	stationary signal
Wavelet Analysis	ได้จากหลาย resolution	ได้ โดยไม่จำกัด window แบบเดียวกับ FFT	จับตำแหน่ง event ได้ดี	เห็นใน scalogram	stationary และ non-stationary
Transformer	ได้จาก attention	ได้ถ้า time delay อยู่ใน context	ได้จาก attention + features	อาจจำกัดตาม context length	stationary และ non-stationary

19. Hackathon / SuperAI Engineer Playbook

19.1 Pipeline มาตรฐานสำหรับโจทย์ Time Series

- 7. เข้าใจโจทย์ธุรกิจ: ต้อง forecast, classify, detect anomaly หรือ explain pattern?
- 8. สำรวจข้อมูล: plot graph, check missing, check outlier, check sampling interval
- 9. แยก pattern: trend, seasonality, holiday effect, cycle
- 10. ทำ baseline: naive forecast, moving average, ARIMA หรือ simple ML
- 11. Feature engineering: lag features, rolling mean/std, calendar features, FFT/Wavelet features ตามโจทย์

12. เลือกโมเดล: ARIMA/CNN/Fourier/Wavelet/Transformer ตามลักษณะข้อมูล
13. วัดผล: MAE, RMSE, MAPE, Bias และ metric เฉพาะงาน เช่น F1 สำหรับ anomaly
14. ทำ visualization: actual vs predicted, residual plot, spectrum/spectrogram/scalogram, attention map
15. แปลผลเป็น impact: ลด stockout, ลด waste, เตือนล่วงหน้า, ลด downtime

19.2 Factory / Supply Chain Examples

Problem	Pipeline ที่แนะนำ	Model ที่ใช้ได้	Demo ที่กรรมการเข้าใจง่าย
ทำนายวัตถุดิบ	clean -> lag/rolling/calendar -> forecast	ARIMA, XGBoost, Transformer, Informer	กราฟ actual vs forecast + alert stockout
ตรวจ anomaly การใช้วัตถุดิบ	theory vs actual -> residual -> anomaly score	Isolation Forest, CNN, Autoencoder	dashboard จุดแดงว่าใช้เกินปกติ
เครื่องจักรสันผิปกติ	vibration -> FFT/spectrogram -> classifier	FFT+ML, CNN	โชว์ spectrum ก่อน/หลัง abnormal
เสียงเครื่องจักร	audio -> spectrogram -> Conv2D	CNN	heatmap spectrogram + class result
EEG/ECG/heart sound	signal -> wavelet/scalogram -> model	Wavelet + CNN	ภาพ scalogram + abnormal probability
forecast ยาวหลาย feature	windowing -> embeddings -> seq2seq	Transformer/Informer	forecast 7 วันข้างหน้า + confidence band

19.3 Feature Engineering ที่ใช้บ่อย

Feature	ตัวอย่าง	ใช้กับโมเดล
Lag features	$y(t-1)$, $y(t-7)$, $y(t-30)$	ARIMA, ML, Transformer
Rolling statistics	rolling mean/std/min/max	ML, anomaly detection
Calendar features	day of week, month, holiday flag	forecast demand/sales
Difference features	$x_t - x_{t-d}$	ARIMA, stationarity
FFT features	top frequency, spectral power	vibration/audio/seasonality
Wavelet coefficients	detail coefficients หลาย scale	EEG/ECG/noisy signal
Residual features	actual - prediction/baseline	anomaly detection
Time embedding	positional/time stamp embedding	Transformer/Informer

20. จุดที่ควรถามตัวเองก่อนเลือกวิธี

คำถาม	ถ้าคำตอบเป็นแบบนี้	วิธีที่นึกถึง
ต้องทำนายอนาคตไหม	ใช่ และข้อมูล season ชัด	ARIMA / SARIMA / Prophet-like / Transformer
ข้อมูลมี missing ไหม	ใช่	Interpolation + missing flag
pattern อยู่ในช่วงเวลาสั้น ๆ ไหม	ใช่	CNN/Conv1D
signal มีความถี่หรือคลื่นไหม	ใช่	FFT / Fourier / Spectral Density
frequency เปลี่ยนตามเวลาไหม	ใช่	Spectrogram หรือ Wavelet
signal noisy/non-stationary ไหม	ใช่	Wavelet/Scalogram
ต้องจับ dependency ไกล ๆ ไหม	ใช่	Transformer/Informer
sequence ยาวมากไหม	ใช่	Informer หรือ efficient attention
ต้อง explain ให้คนธุรกิจเข้าใจไหม	ใช่	ARIMA baseline + กราฟ + metrics + simple rules

21. Cheat Sheet อ่านก่อนสอบ

คำสำคัญ	จำแบบสั้น
Time Series	ข้อมูลเรียงตามเวลา
Forecasting	ทำนายอนาคตจากอดีต
Stationary	mean/variance/autocovariance ไม่เปลี่ยน
Trend	แนวโน้มระยะยาว
Seasonality	pattern ซ้ำเป็นรอบคงที่
Holiday Effect	event พิเศษทำให้ข้อมูลผิดปกติ
Cycle	วัฏจักรยาว ไม่สม่ำเสมอ
ARIMA	อดีต + differencing + error
Interpolation	เติมค่าที่หาย
MAE	ผิดเฉลี่ยที่หน่วย
RMSE	ลงโทษ error ใหญ่
MAPE	ผิดกี่เปอร์เซ็นต์
Bias	ทำนายสูง/ต่ำเกินจริง
Convolution	kernel เลื่อนหา pattern
CNN	เรียน kernel เอง
Fourier	แยก signal เป็น frequency
FFT	Fourier แบบเร็ว $O(n \log n)$
Spectrogram	FFT หลาย window เป็น heatmap

Wavelet	คลื่นสั้น จับเวลา+frequency
FWT	Wavelet แบบเร็ว
Scalogram	ภาพจาก wavelet
Attention	เลือกสนใจตำแหน่งสำคัญ
Self-Attention	sequence สนใจตัวเอง
Cross-Attention	target สนใจ source
Multihead	หลาย attention หลายมุมมอง
Informer	Transformer สำหรับ long time series

21.1 สูตรจำ 1 บรรทัด

จำแบบเร็ว

ARIMA ดูอดีต | CNN หาราย | Fourier หาดคลื่น | Wavelet หาดคลื่นพร้อมตำแหน่ง | Transformer หาความสัมพันธ์ไกล | Informer ทำ Transformer ให้ไหวกับ sequence ยาว

21.2 เทคนิคตอบข้อสอบ

ถ้าข้อสอบถามว่า “ควรใช้วิธีไหน” ให้ตอบ 4 ส่วน: 1) ลักษณะข้อมูล 2) วิธีที่เลือก 3) เหตุผล 4) ข้อจำกัด

ตัวอย่างคำตอบ	โครงตอบที่ดี
ข้อมูลเป็นเสียงพูด	แปลงเป็น spectrogram แล้วใช้ CNN เพราะเสียงมี pattern ใน time-frequency domain และ CNN จับ local pattern บนภาพได้ดี ข้อจำกัดคือ window size มีผลต่อ resolution
ข้อมูล EEG noisy	ใช้ Wavelet/Scalogram + CNN เพราะ EEG เป็น non-stationary และ wavelet เห็นทั้งตำแหน่งเวลาและความถี่ ข้อจำกัดคือต้องเลือก wavelet/scale
ยอดขายมี season รายสัปดาห์	เริ่มด้วย ARIMA/SARIMA หรือ baseline + calendar features เพราะอธิบายง่าย ข้อจำกัดคือ nonlinear pattern อาจต้องใช้ ML/Transformer เพิ่ม

22. Mini Examples สำหรับเข้าใจเร็ว

Example 1: Demand Forecasting ในโรงงาน

Step	ทำอะไร	เหตุผล
1	Plot material consumption รายชั่วโมง	ดู trend/season/outlier
2	เติม missing ด้วย interpolation	ทำ timeline ให้ครบ
3	สร้าง lag: t-1, t-24, t-168	จับรายชั่วโมง/รายวัน/รายสัปดาห์

4	สร้าง holiday/shift feature	จับ effect จากปฏิทินและกะการผลิต
5	ทำ baseline ARIMA หรือ Moving Average	ใช้เทียบกับโมเดลใหญ่
6	ถ้ามีหลาย feature ใช้ Transformer/Informer	จับ dependency ระยะยาว
7	วัด MAE/RMSE/Bias	แปลเป็นหน่วยวัดดูบิที่ต้องเผื่อ

Example 2: Machine Vibration Anomaly

Step	ทำอะไร	เหตุผล
1	เก็บ vibration signal	raw time series
2	ทำ FFT/Spectrogram	ดู frequency ผิดปกติ
3	ใช้ CNN หรือ ML classifier	แยก normal/abnormal
4	วัด Precision/Recall/F1	alarm ผิดหรือหลุดมีต้นทุน
5	ทำ dashboard spectrum	อธิบายเหตุผลของ anomaly

Example 3: EEG/ECG Classification

Step	ทำอะไร	เหตุผล
1	Preprocess + filter noise	สัญญาณชีวภาพ noisy
2	ทำ Wavelet Transform	จับ event ตามเวลาและ frequency
3	สร้าง Scalogram	แปลงเป็นภาพ
4	ใช้ Conv2D	CNN จับ local pattern ในภาพได้ดี
5	อธิบาย ridge/peak	ช่วยตีความว่า abnormal อยู่ช่วงไหน

23. สรุปสุดท้าย

บทนี้สอนให้มอง Time Series ได้หลายมุม ไม่ใช่แค่การ forecast แบบเส้นกราฟ แต่สามารถมองเป็น pattern ตามเวลา มองเป็นความถี่ มองเป็นภาพ time-frequency และมองเป็น sequence relation ผ่าน attention

มุมมอง	วิธีหลัก	คำถามที่ตอบได้
Time-domain	ARIMA, CNN/Conv1D	อดีตช่วงไหนช่วยทำนายอนาคต
Frequency-domain	Fourier, FFT, Spectral Density	มีรอบ/ความถี่อะไรซ่อนอยู่
Time-frequency	Spectrogram, Wavelet, Scalogram	frequency ไหนเกิดช่วงเวลาใด
Attention-based	Transformer, Informer	ตำแหน่งใดใน sequence สำคัญต่อการทำนาย

เริ่มจาก baseline ง่าย ๆ ก่อน แล้วค่อยเพิ่มความซับซ้อน: ARIMA/Moving Average -> Feature Engineering -> CNN/FFT/Wavelet -> Transformer/Informer ตามลักษณะข้อมูลและเวลาที่มี