

Insight from industry

Tor (กรรมกรบ้าน Scamper) 05/2026



About me


- ป.ตรี ICE, Chula
- ป.โท AI for Biomedicine, UCL
- [15 years] 4 Startup / 1 Company, all related to AI
 - CTO / Tech-lead / Founding Engineer / Data scientist
 - demand forecast, recommender system, Thai NLP, information extraction, OCR, fraud detection, credit scoring, immunology AI, AI coding
- 1st National Software Contest
 - speech detection with SVM
- ผลงานวิชาการ
 - [SOTA] fastest nearest neighbor search algorithm on immunology
 - solving ARC-AGI with symbolic few-shot learning and tiny-scale ml



Overview


1. business understanding
2. data understanding
- ~~3. pre-processing~~
- ~~4. modeling~~
- ~~5. evaluation~~
3. post-processing
4. deployment / lifecycle

* Focus on principle
with example from Amazon



1. Business understanding

- ให้เฝ้ามอยเยอะๆ ถ้ามเยอะๆ อย่าเป็นนักรบห้องแอร์



Example insight from stakeholders

- analyst
 - ยอดต่อบิล / RFM / same-store growth / ลูกค้าขาจร ขาประจำ / สาขาเกรด A
 - [usage] feat eng from existing analysis
- shopkeeper
 - product incentive / new competitor
 - [usage] internal process / localized feature
- marketing
 - disney-cup limited edition / campaign pattern
 - [usage] manual reorder / extra rules
- logistics
 - route optimization / reorder process / minimum-maximum order / supplier ปิดสงกรานต์
 - [usage] extra rules

Insight about money

- cost structure
 - what's the top cost?
- margin
 - high / low margin? which product?
- revenue structure
 - ยอดขายรวม = ยอดขาย
- who is the payer?
 - ซื้อขาด? ฝากขาย?

Insight about context: สาขา

- การเดินทางมาของลูกค้า: BTS? เดิน? ขับรถ?
- ลักษณะลูกค้า: ขาจร / ขาประจำ / นักเรียน
- คู่แข่งในพื้นที่: ราคาใกล้เคียง กลุ่มลูกค้าใกล้เคียง สินค้าใกล้เคียง
- อากาศ: อุณหภูมิ ปริมาณฝน
- ปัจจัยอื่น: วันเปิดเทอม วันเทศกาล

Question

1. Loss function ควรเลือกอะไร เพราะอะไร?

a. MAE / MSE / MSLE

$$\text{MAE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} |y_i - \hat{y}_i|. \quad \text{MSE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} (y_i - \hat{y}_i)^2.$$

$$\text{MSLE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} (\log_e(1 + y_i) - \log_e(1 + \hat{y}_i))^2.$$


2. หากโมเดลทำนายผิด ทำนายมากไปหรือน้อยไปดีกว่ากัน?
3. ข้อ 2 ส่งผลกระทบต่อ loss function หรือไม่?
4. ข้อขาด / ฝากขาย ส่งผลกระทบต่อ loss function หรือไม่?
5. ถ้าเรารู้ว่า marketing กำลังจะจัดโปรแรงมีลิซ่าเป็นพรีเซนเตอร์ เราจะทำอย่างไร?
6. หากเปลี่ยนโจทย์เป็นการวินิจฉัยโรค (เป็น/ไม่เป็น) ทำนายผิดจะมีผลอย่างไร

2. Data Understanding


- data engineering
- auto EDA
- actionable insight

Data Engineering Basics

- data character: API / FTP / website scraping / website crawling / 4V
- tools: AirFlow / Google Workflow / FireCrawl / Python script
- maintenance: upstream change and pipeline error
- etc: staging zone and idempotency



ENTERPRISE DATA WAREHOUSE COMPONENTS



AutoEDA Example: Y-Profiling

cholesterol

Categorical

Distinct	3
Distinct (%)	< 0.1%
Missing	0
Missing (%)	0.0%
Memory size	547.0 KiB

```
profile = ProfileReport(df, title="YData Profiling Report")
```

[More details](#)

Overview

Categories

Words

Characters

Length

Max length	1
Median length	1
Mean length	1
Min length	1

Characters and Unicode

Total characters	70000
Distinct characters	3
Distinct categories	1 ?
Distinct scripts	1 ?
Distinct blocks	1 ?

The Unicode Standard assigns character properties to each code point, which can be used to analyse textual variables.

Unique

Unique	0 ?
Unique (%)	0.0%

Sample

1st row	1
2nd row	3
3rd row	3
4th row	1
5th row	1


AutoEDA Example: Y-Profiling

Correlations

Auto

Heatmap

Table




Outliers

Standard Deviation

Variance

PCA projection



AutoEDA Example: Y-Profiling

Overview

Overview

Alerts 28

Reproduction

Alerts

source has constant value "NASA"

Constant

Dataset has 10 (< 0.1%) **duplicate rows**

Duplicates

name has a high cardinality: 45716 distinct values

High cardinality

recclass has a high cardinality: 466 distinct values

High cardinality

GeoLocation has a high cardinality: 17100 distinct values

High cardinality

reclat is highly correlated with **reclong** and 1 other fields

High correlation

reclong is highly correlated with **reclat** and 1 other fields

High correlation

Actionable Insight

- หลังจาก EDA เราอาจได้ insight มากมาย แต่ไม่ใช่ทุกอันจะสามารถใช้ประโยชน์ได้
- มักจะ specific, situation explaining, actionable
- สำคัญมากเมื่อทำ dashboard / presentation

1. E-Commerce / User Experience (UX)

- **Raw Data:** "55% of users abandon their digital shopping cart."
- **General Insight:** "Our checkout process is too long."
- **Actionable Insight:** "Data shows that 55% of mobile users abandon the cart on the shipping details page. **Action:** Remove the three-step shipping form and replace it with a single-page, autofill-compatible checkout to reduce mobile friction."  Medium · Nick Spreen

2. Physical Operations & Manufacturing

- **Raw Data:** "Machine A breaks down frequently."
- **General Insight:** "Our factory needs better maintenance."
- **Actionable Insight:** "Sensor data reveals Machine A overheats and breaks down after 150 hours of continuous high-speed operation. **Action:** Program the automated system to pause Machine A for a 15-minute cooling period every 120 hours, eliminating unexpected repair downtime."  Adobe for Business +2

3. Customer Service & Support

- **Raw Data:** "Our Net Promoter Score (NPS) dropped 10 points this month."
- **General Insight:** "Customers are unhappy with the recent update."
- **Actionable Insight:** "Text analysis of customer reviews reveals that 75% of complaints mention a bug in the new mobile app login screen. **Action:** Roll back the login update to the previous stable version while the development team patches the error."  www.lumoa.me +1

4. Marketing & Content Strategy

- **Raw Data:** "We are getting lots of website traffic, but no leads."
- **General Insight:** "People don't like our services."
- **Actionable Insight:** "Analytics show that visitors from social media spend an average of 4 seconds on our pricing page before leaving. **Action:** A/B test a more transparent pricing chart and add a live chat widget specifically to those social media landing pages to capture leads."  CGI.com

3. Post-processing


- คนมักชอบลืม
- context dependent
 - rounding / min-max / negative value
 - integrity check (spell checking, db lookup, document formatting)
 - smoothing consecutive prediction
 - probability calibration
 - image upscale / downscale

4. Deployment / Lifecycle


- MLOps
- post-mortem analysis
- A/B testing
- human-in-the-loop design
- idea proposing (extra)

MLOps Overview

- MLOps = automatic ML training/deployment pipeline (similar to CI/CD)
- [why] changes are frequent
 - code, input output distribution, product, campaign, calendar feature, concept drift
- [why] model evaluation is harder than software testing
- [why] model, data, feature needs versioning (not just code)



MLOps Example



Post-mortem Analysis

- post-mortem analysis = the investigation after bad things happen
- from stakeholder, model performance drop, software bug, LLM
- example: distribution shift from free visa in july 2024
 - many Amazon customers are tourist (like motorway or tourist spot)
 - สภาพัฒน์บอก การท่องเที่ยวไทยโต 36.8% (Q4 2024 vs Q4 2023)
 - แบงก์ชาติบอก ปริมาณตัวเครื่องบินเข้าไทยโต 10-20% (Q4 2024 vs Q4 2023)
 - แต่งบการเงินภาพรวมของ PTT OR ไม่กระทบ (Q4 2024 vs Q4 2023)
- [possible action] rule-base decision จาก macro economic analysis
- [possible action] เพิ่ม feature ปริมาณตัวเครื่องบินเข้าไทย

Post-mortem Analysis



@Touchchai ผลscoreครับอาจารย์ที่น้องทำเมื่อวาน 2อันบนผมลองแล้วprivateดีที่สุด
ในleaderboardคับ

Submission and Description	Private Score	Public Score	Selected
✓ submission_postprocessed.csv Complete · Private · 8h ago	9.4350	8.8079	☐
✓ submission_scorepush_selected_capped.csv Complete · Private · 7h ago	9.4505	8.7838	☐
✓ Super AI Engineer Submission Averaged.csv Complete · 10h · 1h ago	9.5149	8.6807	☒

 1 



EC_EI_028_S2 Tourism Indicators

EC_EI_028_S2 Tourism Indicators

Service Manager Public and Real Sector Data Management Team

Sort Period

Download

Print

Metadata

Frequency

Monthly

From

October

2024

To

December

2024

(JAN 2015 – MAR 2026)

Submit

Last Updated : 30 Apr 2026 14:30

(Unit: as stated)

	DEC 2024	NOV 2024	OCT 2024
1. Number of foreign tourists visiting Thailand (in thousands)	3,627.44	3,150.24	2,679.18
2. Accommodation occupancy rate (percent)			



	DEC 2023	NOV 2023	OCT 2023
1. Number of foreign tourists visiting Thailand (in thousands)	3,261.26	2,637.08	2,197.02

2024

2023


A/B Testing and Human-in-the-loop

- A/B testing is a experiment in production technique using statistics and multiple copies of the pipeline
- Human-in-the-loop is a deployment
- They can reduce risk, improve confidence, and promote experimentation



Idea proposing

- หลายครั้งหน้าที่ของ data scientist อาจเกี่ยวกับการนำเสนอ/ทดลองไอเดียใหม่ๆ
- หากเราทำได้ดี ก็จะมีความก้าวหน้า ทีมเติบโต บริษัทกำไรเพิ่ม และได้งบประมาณเพิ่ม
- การเสนอปรับปรุงประสิทธิภาพมักจะคุ้มค่า เมื่อคิด life-time value
 - เช่น ทำโปรเจกต์ใช้เงิน 1 ล้านบาท ได้กำไรเพิ่มปีละ 5 แสน (คืนทุน 2 ปี) และโปรเจกต์นี้ใช้ได้ 10 ปี
 - กล่าวคือ หากโปรเจกต์เวิร์คจะได้กำไรเพิ่ม 4 ล้านบาท แต่หากไม่เวิร์คจะขาดทุน 1 ล้านบาท
- เทคนิคที่แนะนำคือการทำ proof-of-concept เพื่อลด risk และทำไอเดียให้เป็นรูปธรรม ก่อนเริ่มโปรเจกต์จริง
- business understanding first, technology second
- ปัจจุบัน vibe coding ยิ่งทำให้การทดลองอะไรใหม่ๆ หรือสร้าง prototype ทำได้ง่ายมาก



Thank you